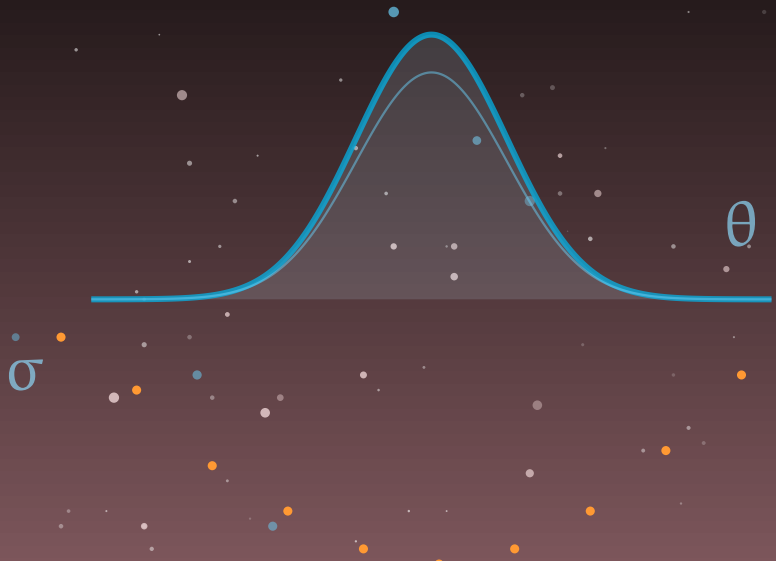
2026 年 9 月重排版

Monikalover



Statistical Inference

统计推断

Adapted from Hiroshi Yuki's *Math Girls* series

提示信息

这是结城浩《数学女孩》系列的非商业同人创作作品。

原作共有 7 本，最新的《黎曼猜想》[①]（日文版出版于 2025 年 8 月）尚无中文版。这里采取的排版方式在一定程度上有意与原作相似，但不能做到完全相同。

本次重排增补了部分注释。文中的空白页是有意为之的，是为使各章标题均出现在右手页（奇数页）。

如果你真的不喜欢数学公式，请在序言后直接从第 6 章开始阅读。

访问 hyuki.com/girl 可获得原作信息。

[①]結城浩《数学ガール / リーマン予想》, SB クリエイティブ

$$\lim_{n\to\infty} P(Z_n \leqslant \heartsuit) = \int_{-\infty}^{\heartsuit} \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right) dx = \Phi(\heartsuit)$$

目录

序言：致往昔的斜阳与风 vii

第 1 章　独立同分布的未来 1

1.1 总体与样本 1

1.2 中心极限定理 7

1.3 随机变量的数字特征 11

1.4 Dirac Delta 15

1.5 不确定性的未来 18

第 2 章　参数估计 21

2.1 最大似然估计 21

2.2 偏差与方差 25

2.3 均方误差 30

2.4 置信区间 33

2.5 硬币公平吗 35

第 3 章　多元统计与回归分析 39

3.1 协方差 39

3.2 条件分布 42

3.3 相关系数与线性回归 49
3.4 随机向量与协方差矩阵 57
3.5 多元线性回归 62

第 4 章 假设检验 67
4.1 p 值与临界值 67
4.2 正态分布的朋友们 71
4.3 卡方拟合优度检验 81
4.4 t 分布与 t 检验 86

第 5 章 数据科学与机器学习 91
5.1 数据预处理与探索性分析 91
5.2 回归模型的选择与评价 96
5.3 模型训练与调优 102
5.4 机器学习的基本任务 104

第 6 章 向夜晚奔去 109
6.1 未来与选择 109
6.2 频率学派与贝叶斯学派 111
6.3 深度学习与人工智能 115
6.4 向夜晚奔去 120

尾声 123

后记 125

序言：致往昔的斜阳与风

风把我不想知道的事情 告诉我

河把我不想忘记的故事 也带走

——ilem《白鸟过河滩》

那是一个樱花绽放的春天
在斐波那契的静谧中我们相连
那是一个寒风凛冽的冬天
在费马大定理的深邃中我们依偎
那是一个骄阳似火的夏天
在随机算法的信步中我们共勉
那是一个万物飘零的秋天
在黎曼猜想的迷惘中我们告别

造物主啊，可否恳求您令我们多留一瞬
再一次见证那往日的斜阳与风
用数学的语言将我们共同的背影描画
再一次前往那理想世界的彼岸
用符号与逻辑构建无可替代的羁绊

我们将面对更为广大的未来
不确定性的迷雾将我们笼罩
那些参数与变量，我们真的知晓吗？
那些假设与选择，我们真的相信吗？
承诺的价值，是否能超越大洋的彼岸？
思想的利椽，是否能突破尘网的樊笼？
无人知晓，无人保证
——凡是过往，皆为序章

第 1 章

独立同分布的未来

1.1 总体与样本

米尔嘉。

不知怎么的，总是忘不了这个名字。纵然相去万里，仍觉犹在耳畔。

“数学是无处不在的，所以米尔嘉也是无处不在的，一定是这样。”我对自己说。

大学的数学和高中的数学还是有所不同，抽象的概念，严谨的证明，多元的应用，然而在米尔嘉过去三年的“调教”下，我竟没有感到特别不适应。

全世界有 80 多亿人，如果从里面随机抽选人的话，应该适用独立同分布假设吧。如果是这样，那我和米尔嘉就是其中的两个样本。如果引入正态分布假设的话，米尔嘉就是 3σ，嗯，一定是这样的。

和她相比，也许我只是一个 1σ，学习考试也是中规中矩，解课本上的那些习题也不成问题。

问题 1.1.1

给定总体 $\mathrm{Exp}(\theta)：f(x)=\theta e^{-\theta x}$（$x>0$）和样本 $X_1,\cdots,X_n$，求 θ 的矩估计量 $\hat{\theta}$。

利用样本估计总体，这是统计推断的核心任务。而矩估计，就是假设样本的矩等于总体的矩。在这里使用一阶原点矩（期望）即可。样本矩就是样本平均值 $\bar{X}$，而总体矩则需要运用一点点微积分知识。

$$\mathbb{E}[\mathrm{Exp}(\theta)]=\int_0^{\infty} x\cdot\theta e^{-\theta x}dx=\frac{1}{\theta}$$

这样，令两者相等，即 $\frac{1}{\hat{\theta}}=\bar{X}$，结果就出来了。

解答 1.1.1

$$\hat{\theta}=\frac{1}{\bar{X}}=\frac{1}{\frac{1}{n}\sum_{i=1}^{n}X_i}$$

我开始看下一道题。

问题 1.1.2

给定总体 $N(\mu,1)$ 和样本 $X_1,\cdots,X_n$，求估计量 $\hat{\mu}=\bar{X}$ 的偏差和方差。

熟悉的正态分布，这个估计量是无偏的，而方差 $\mathbb{E}_\mu[(\hat{\mu}-\mathbb{E}_\mu[\hat{\mu}])^2]=\mathbb{E}_\mu[\hat{\mu}^2]-\mu^2$。

这里的 $\mathbb{E}_\mu[\hat{\mu}^2] = \mathbb{E}_\mu[\frac{(X_1+\cdots+X_n)^2}{n^2}] = \frac{1}{n^2}(Var(X_1 + X_2 + \cdots + X_n) + (\mathbb{E}_\mu[X_1 + \cdots + X_n])^2)$。由于独立同分布，随机变量和的方差等于方差的和，其值为 $1 \times n = n$；由于期望的线性性质，和的期望等于期望的和，其值为 $n\mu$。这样，整个方差就可以这样表示：

$$Var(\hat{\mu}) = \frac{1}{n^2}(n + n^2\mu^2) - \mu^2 = \frac{1}{n} + \mu^2 - \mu^2 = \frac{1}{n}$$

解答 1.1.2

$$bias(\hat{\mu}) = 0, Var(\hat{\mu}) = \frac{1}{n}$$

独立同分布，是统计推断中一个非常重要的假设。

中心极限定理、大数定律，统计世界中的那些基石，无一不依赖于这一假设。在参数估计中，也总是假设样本满足独立同分布。

我、米尔嘉、泰朵拉、尤里、理纱……那些与之一起探寻数学海洋的挚友，那些为了相似的目标一同鏖战的战友，是否也就此别过，走上了独立同分布的旅途？

⊙ ⊙ ⊙

“学长，我这次模拟考考到了 70 分！”

泰朵拉是我的学妹，现在高三，正处于人生的关键时刻。

所谓偏差值，就是用比平均值高多少个标准差，来衡量在全体考生中的表现。

$$D = \frac{z - \mu}{\sigma} \times 10 + 50$$

偏差值为 70，相当于比平均值高出了 2 个标准差。按照百分位换算的话，就是 $\Phi(2) = 0.97725$。这个分数，足以上几乎所有国公立大学。

“谢谢学长一直以来教我数学！如果没有学长，我或许还是那个不会解方程的笨蛋吧。”

我又想起了那些在图书馆和“豆子”咖啡馆的日子。会不会，有那样一天，时间真的能倒流呢？

⊙　⊙　⊙

问题 1.1.3

设某地生产的全部青椒为总体，总体中一个青椒的质量（单位：克）服从正态分布。对于青椒按照以下方法进行分类：

- 质量不超过均值的记为 S 号；
- 超过均值的记为 L 号。

定义：一个 S 号和一个 L 号组合，组合成功即凑成一袋。那么，至少抽取多少个青椒，才能使得能够组成 25 袋的概率不低于 0.95？

这是我和泰朵拉在高中时曾经讨论的题目。

“最少的情况，应该是 50 个吧。如果正好有 25 个是 S，另外 25 个是 L，就能正好形成 25 袋了。不过，这样组合成功的概率应该不高吧。”泰朵拉专注地思考着。

抽取 50 个，其中恰有 25 个是 S 号，也就是二项分布 $B(50, 0.5) = 25$ 的概率：

$$\binom{50}{25} 0.5^{25}(1-0.5)^{25} \approx 0.112$$

“如果抽取 n 次，抽出的 S 号数量为 $X \sim B(n, 0.5)$，那么能组成的袋数就是 $\min(X, n-X)$，而 $\min(X, n-X) \geqslant 25$ 又可以转化为 $25 \leqslant X \leqslant n-25$。这样，相应的概率可以写成：

$$P(\min(X, n-X) \geqslant 25) = \sum_{k=25}^{n-25} \binom{n}{k} 0.5^k (1-0.5)^{n-k}$$

可是，这样的式子真的能解出来吗？

“为什么不试试正态近似呢？”米尔嘉突然出现在我身后。

⊙ ⊙ ⊙

二项分布 $B(n, p)$ 可以用 $\mathcal{N}(np, np(1-p))$ 近似，在这里则是 $\mathcal{N}(0.5n, 0.25n)$。相应的 X 范围原本是 $[25, n-25]$，在这里需要利用连续性校正，成为 $[25-0.5, n-25+0.5]$，也就是 $[24.5, n-24.5]$。

“为什么这里需要校正呢？”

因为二项分布的变量是离散值，将其用连续的正态分布近似的时候，需要对端点加以 0.5 的修正，来提高近似的准确性。

为了方便查正态分布表，现在对端点值利用 $\mu = 0.5n, \sigma = 0.5\sqrt{n}$ 进行标准化：

$$\frac{24.5 - 0.5n}{0.5\sqrt{n}} = \frac{49}{\sqrt{n}} - \sqrt{n}$$

$$\frac{n-24.5-0.5n}{0.5\sqrt{n}}=\sqrt{n}-\frac{49}{\sqrt{n}}$$

这样，就可以表示出 X 落在相应区间中的概率：

$$\begin{aligned}P(X\in[24.5,n-24.5])&=\Phi\left(\sqrt{n}-\frac{49}{\sqrt{n}}\right)-\Phi\left(\frac{49}{\sqrt{n}}-\sqrt{n}\right)\\&=1-2\Phi\left(\frac{49}{\sqrt{n}}-\sqrt{n}\right)\geqslant 0.95\end{aligned}$$

也就是说，$\Phi(\frac{49}{\sqrt{n}}-\sqrt{n})\leqslant 0.025$，查表可得 $\frac{49}{\sqrt{n}}-\sqrt{n}\approx -1.96$，解得 $n\approx 64.77$。因此，要使得概率值不少于 0.95，至少要抽取 65 个青椒。

解答 1.1.3

至少抽取 65 个青椒，才能使得能够组成 25 袋的概率不低于 0.95。

⊙　⊙　⊙

“服从二项分布的随机变量，原来可以使用正态分布来近似吗？”泰朵拉恍然大悟。

“其实二项分布可以看成 n 次伯努利试验的和。当实验次数足够多了的时候，根据中心极限定理，这个和依分布收敛于正态分布。”我补充道。

“依分布收敛……那是什么？”泰朵拉脸上写满了疑惑。

“依分布收敛就是分布函数的弱收敛——好疼！”米尔嘉突然捏了我一下。

“又在吓唬小学妹啦，××[①]~”

我能感到我的脸颊突然在发烫，这到底是为什么呢?

不过没有时间思考了，因为米尔嘉已经在泰朵拉身边解释起来。

1.2 中心极限定理

在刚刚的问题中，我们选择 n 个青椒，用 X_i 表示第 i 个青椒是否为 S 号，可以写成 $X_i \sim Ber(0.5)$。这里的 Ber 就表示伯努利分布。$Ber(0.5)$ 表示 X_i 有 0.5 的概率为 1，另外 0.5 的概率为 0。这样，二项分布 $X \sim B(n, 0.5)$ 可以换一种形式来表达：

$$X = \sum_{i=1}^{n} X_i$$

中心极限定理告诉我们，当 n 足够大的时候，X 服从一个正态分布。这个正态分布的期望和方差可以计算出来：

$$\mathbb{E}[X] = \sum_{i=1}^{n} \mathbb{E}[X_i] = 0.5n$$

在算方差的时候，我们需要引入一个重要的假设，独立同分布。这就是说，每一次取青椒的结果互不影响，且都服从相同的伯努利分布。此时，有 $Var(X_i + X_j) = Var(X_i) + Var(X_j)$。也就是说：

$$Var(X) = Var\left(\sum_{i=1}^{n} X_i\right) = nVar(X_1) = n \cdot 0.5(1 - 0.5) = 0.25n$$

[①]原作的男主就是没有名字的。

所谓“依分布收敛于正态分布”，就是说有这样一个随机变量 $X^* \sim \mathcal{N}(0.5n, 0.25n)$，使得 X 的分布列随着 n 的增大，越来越像 X^* 的分布列。

“那 X^* 和 X 需要满足独立同分布假设吗?”

并不需要，因为我只关心它们的分布列之间是否越来越接近，而不关心它们的具体取值有何关联，这就是“依分布收敛”的核心意义。换言之，任何服从正态分布 $\mathcal{N}(0.5n, 0.25n)$ 的随机变量，都是 X 依分布收敛的对象。所以这时我们可以直接说“X 依分布收敛于给定的正态分布”，而不需要再定义一个新的具体随机变量。

“那如果 X_i 不是伯努利分布的话，还能用中心极限定理吗?”

当然可以，只要 X_i 是独立同分布的，$X = \sum_{i=1}^{n} X_i$ 就会依分布收敛于
$\mathcal{N}(n\mathbb{E}[X_1], n\mathrm{Var}(X_1))$，均值 $\bar{X} = \frac{X}{n}$ 依分布收敛于 $\mathcal{N}(\mathbb{E}[X_1], \frac{\mathrm{Var}(X_1)}{n})$。或者说，就算 X_i 不是同分布的，只要满足独立性，也只要稍加修改形式，就能应用中心极限定理。

⊙ ⊙ ⊙

“讲到这里，我们来做一个练习如何?”米尔嘉开始写了起来。

问题 1.2.1

假设 $X_1, X_2, \cdots, X_n, \cdots \sim \mathrm{Poi}(\lambda)$ 独立同分布，即 $P(X_i = k) = e^{-\lambda}\frac{\lambda^k}{k!}$（$k = 0, 1, 2, \cdots$），利用中心极限定理，求出 $\bar{X} = \frac{1}{n}\sum_{i=1}^{n} X_i$ 的依分布收敛。

“你先别说话，让她自己想。”米尔嘉瞪了我一眼。虽然有点委屈，但也没办法。

“嗯，之前说其实 $\bar{X}$ 依分布收敛于 $\mathcal{N}(\mathbb{E}[X_1], \frac{Var(X_1)}{n})$”，所以只需要求出 X_1 的期望和方差就行了。这个 Poi 是什么意思呢？难道是在卖萌？”泰朵拉眨着眼睛，嘴巴也做出了“poi”的口型。

“这叫泊松分布，用来刻画发生率很低的事件。这里给出了它的分布列，按照定义来做就能解决啦。”米尔嘉笑盈盈地看着泰朵拉。

什么时候能对我这么耐心呢？

“根据定义的话，就是要先求出泊松分布的期望和方差。这是一个离散随机变量，所以期望应该写成一个无穷级数……”泰朵拉边说边写。

$$\mathbb{E}[X_1] = \sum_{k=0}^{\infty} k e^{-\lambda} \frac{\lambda^k}{k!} = e^{-\lambda} \sum_{k=0}^{\infty} k \frac{\lambda^k}{k!}$$

“唔，右边这个求和好像有点难呢……”

“你写几项试试。”米尔嘉在一旁提示道。

泰朵拉开始写起这个求和表达式。

$$\sum_{k=0}^{\infty} k \frac{\lambda^k}{k!} = \lambda + \lambda^2 + \frac{\lambda^3}{2!} + \cdots = \lambda \left(1 + \lambda + \frac{\lambda^2}{2!} + \cdots \right)$$

“是学长教我的泰勒展开！”

泰朵拉继续推起了式子。

$$\mathbb{E}[X_1] = e^{-\lambda} \sum_{k=0}^{\infty} k \frac{\lambda^k}{k!} = e^{-\lambda} \cdot (\lambda e^{\lambda}) = \lambda$$

一辈子也不会忘记——当我教泰朵拉泰勒展开时，她是这么说的。

“接下来只要求出方差就好了。”

$$
\begin{aligned}
Var(X_1) &= \mathbb{E}[X_1^2] - \lambda^2 \\
&= \sum_{k=0}^{\infty} k^2 e^{-\lambda} \frac{\lambda^k}{k!} - \lambda^2 \\
&= e^{-\lambda}\lambda \left(\sum_{k=0}^{\infty} k \frac{\lambda^{k-1}}{(k-1)!} \right) - \lambda^2 \\
&= e^{-\lambda}\lambda \left(\sum_{k=1}^{\infty} (k-1) \frac{\lambda^{k-1}}{(k-1)!} + \sum_{k=1}^{\infty} \frac{\lambda^{k-1}}{(k-1)!} \right) - \lambda^2 \text{①} \\
&= e^{-\lambda}\lambda \left(\lambda \sum_{k=2}^{\infty} \frac{\lambda^{k-2}}{(k-2)!} + e^{\lambda} \right) - \lambda^2 \\
&= e^{-\lambda}\lambda(\lambda e^{\lambda} + e^{\lambda}) - \lambda^2 \\
&= \lambda^2 + \lambda - \lambda^2 \\
&= \lambda
\end{aligned}
$$

泰朵拉的泰勒展开已经相当熟练。

随着期望和方差的导出，也就得到了最终的结果。

解答 1.2.1

$\bar{X}$ 依分布收敛于 $\mathcal{N}(\lambda, \frac{\lambda}{n})$。

“也就是说，即使 X_i 是偏态的，只要数量足够多，最终也能收敛到一个正态分布上。”米尔嘉说。

① 注意到这里的求和下限进行了变更，这是因为对于 $k\lambda^k/k!$ 这一项而言，当 $k = 0$ 时其极限为 0，后续的变下限操作原理类似。此处利用 $k = (k-1) + 1$ 对求和进行了拆分。

“中心极限定理……英文是叫 Central Limit Theorem 吧？这里的 Central，指的是正态分布的中心吗？”泰朵拉若有所思。

“可以这样理解。不过这里的 Central 也可以表示这个定理在统计学中很重要，处于中心地位的意思。统计当中的很多推断方法，都是以这个定理为基础的。”

说着，米尔嘉戳了一下我的腰。

“确实，参数估计和假设检验都普遍以中心极限定理作为基础。还有，能不要戳我了吗？好痒。”我并不真诚地抱怨道。

“这个嘛……看你表现咯。”米尔嘉假装不在意地说。

⊙ ⊙ ⊙

现在，没有“豆子”，没有 Iodine，只有定义、公式与算法。

大数定律阐明了大量重复试验中频率的稳定性，中心极限定理则阐明了大量独立随机变量的分布稳定性。

然而，仅仅作为一个样本的自己，并没有这样一条定理定律，能够保证自己的稳定性。

我们的轨迹，因为数学产生重叠，产生从相识到相知的收敛。

我们的旅途，因为时间产生分歧，产生从比邻到天涯的发散。

在这个永不停止的随机过程中，究竟怎样的算法，才能留住哪怕一瞬？

也许，还有那样一个非平凡解。

“学长，放假了到双仓图书馆来吗？”

1.3 随机变量的数字特征

双仓图书馆，我，泰朵拉，理纱。

好久没有像这样一起讨论数学了，如果米尔嘉也在就好了。

现在，我是这里最年长的人。在米尔嘉不在的日子里，我应该承担起这个责任。

“之前我们已经提到了随机变量的期望 $\mathbb{E}[X]$ 和方差 $\mathrm{Var}(X)$，还有人记得怎么把方差写成期望的形式吗？”

“我知道！可以写成平方的期望减去期望的平方！”

$$\mathrm{Var}(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2$$

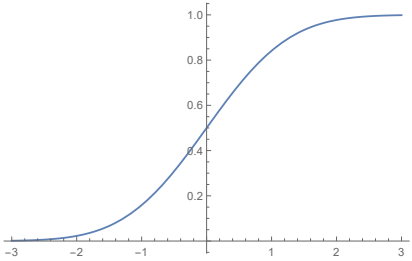
泰朵拉不假思索地回答，而红头发的理纱却似乎仍沉浸在自己的世界中，在电脑上编写着程序。

“如果把方差和期望的概念推广，我们就可以得到名为‘矩’的数字特征。实际上，期望就是一阶原点矩，方差就是二阶中心矩。”

$\mathbb{E}[X^k]$ （k 阶原点矩）　　$\mathbb{E}[(X - \mathbb{E}[X])^k]$ （k 阶中心矩）

“随机变量的数字特征不能反映其全貌。我们可以定义随机变量的累积分布函数 $F(x) = P(X \leqslant x)$，并用这一函数表示关于单一随机变量的全部信息。”

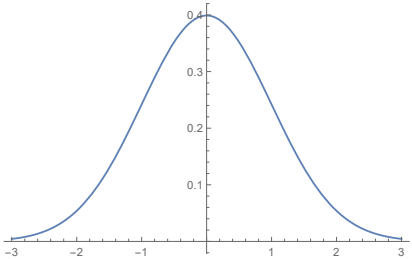
说到这里，理纱突然拍了拍我的肩。



“正态分布，CDF。”理纱像人形电脑一样说道。

“CDF 就是 Cumulative Distribution Function 吧，之前查正态分布表的时候那个 Φ 就是它。”

没错，这就是正态分布的 CDF。将其求导后，就可以得到我们熟悉的钟形曲线了。



这条钟形曲线对应的函数就是正态分布的概率密度函数 ϕ，反映了随机变量分布在某点附近的概率大小。

相等的随机变量对应着相同的分布，也就是相同的累积分布函数。

问题 1.3.1

已知 $P(X = Y) = 1$，求证：$F_X = F_Y$。

“这也要证明吗？这两个随机变量不是一定相等吗？”

“难道概率为 1 的事件就必然发生吗？”我看向泰朵拉。

“难道不是吗？是不是学长在捉弄我？”

这事好像确实比较难说清楚，不过米尔嘉还在的时候讲过概率公理，如果从公理出发应该就能讲明白了。

⊙ ⊙ ⊙

给定一个样本空间 Ω，对于其中的每一个子集 $E \subseteq \Omega$，可以定义其概率 $P(E)$，满足：

- $0 \leqslant P(E) \leqslant 1$；
- $P(\Omega) = 1$；
- 对于可数无穷的 $A_1, A_2, \cdots, A_n, \cdots$ 且 $A_i \cap A_j = \emptyset$，有 $P(\cup_{i=1}^{\infty} A_i) = \sum_{i=1}^{\infty} P(A_i)$。

“为什么最后一条公理比米尔嘉学姐之前讲得复杂许多呢？”泰朵拉不解地问。

这一条公理之所以复杂，是因为其对应的是 σ 代数的可列可加性。之前的有限可加性，实际上是这条公理的一条推论。

假如 $\Omega = (0, 1)$，$E = \Omega \setminus \{0.5\}$，则根据概率公理，有：

$$P(E) + P(\{0.5\}) = P(\Omega) = 1$$

而 $P(\{0.5\})$ 不能取大于 0 的值，也就是说 $P(E) = 1$ 必然成立，但 E 却不是一定发生的事件（$E \neq \Omega$）。

“那要怎么证明两者的分布函数相等呢？”

可以通过定义来证明。

解答 1.3.1

$F_X(t) = P(X \leqslant t) =^{①} P(X \leqslant t, X = Y) = P(Y \leqslant t, X = Y) = P(Y \leqslant t) = F_Y(t)$。

“原来是这样，主观的直觉需要通过严谨的证明来验证。”泰朵拉认真地说。

⊙ ⊙ ⊙

如果有了概率密度函数 $f(x) = F'(x)$，我们就可以将期望写成下面这种形式：

$$\mathbb{E}[X] = \int_{-\infty}^{\infty} x f(x) dx$$

在大部分情况下，$f(x)$ 是一个连续可导的函数。当然，也存在着一些例外。

1.4 Dirac Delta

“Heaviside”，理纱在电脑屏幕上开始敲起了公式。

$$H(x) = 1_{x>0} = \begin{cases} 0 & x \leqslant 0, \\ 1 & x > 0. \end{cases}$$

“这里的 1 带下角标是什么意思呢?”

这是指示函数，英文叫 Indicator Function。顾名思义，就是当

① $P(X \leqslant t) = P(X \leqslant t, X = Y) + P(X \leqslant t, X \neq Y)$，由于 $P(X = Y) = 1$，得 $P(X \neq Y) = 0$，故 $P(X \leqslant t, X \neq Y)$ 为零，因此该等号成立。

右下角的条件满足时为 1，否则为 0。

“原来如此，是否满足条件的 Indicator。”

理纱写的 Heaviside 函数，也叫阶跃函数，它的导数通常记作 $\delta(x)$，称为 Dirac Delta.

$$\delta(x) = \begin{cases} 0 & x \neq 0, \\ \int_{-\infty}^{\infty} \delta(x)dx & = 1 \end{cases}$$

“这个函数在 0 处没有定义吗?”

是的，Dirac Delta 的定义是通过积分来进行的。并不能简单地将 $\delta(0)$ 的值定义为无穷，至少不是我们惯常认知中的那种无穷。

Dirac Delta 能够帮助我们解决一些常规的微积分难以解决的问题。

问题 1.4.1

已知函数 $\psi(x, \theta) = \begin{cases} 1 & x \geqslant \theta, \\ -1 & x < \theta. \end{cases}$，$X$ 为具有分布 $F(x)$ 和密度 $f(x)$ 的连续随机变量，求：

$$\mathbb{E}\left[\frac{d}{d\theta}\psi(X, \theta)\right]$$

“这个期望的式子里面有两个变量，应该对谁做积分呢?”

虽然这里有两个变量，但是真正的随机变量只有 X，所以期望应该是对 X 求积分。

$$\mathbb{E}\left[\frac{d}{d\theta}\psi(X,\theta)\right] = \int_{-\infty}^{\infty} \frac{d}{d\theta}\psi(x,\theta)f(x)dx$$

这里的 ψ 是 Heaviside 函数经过些微变化之后得到的。它在 θ 处有间断点，所以 $\frac{d}{d\theta}\psi(x,\theta)$ 可以写成 $-2\delta(x-\theta)$。

“为什么这里会有一个系数 -2 呢”？

因为它是从 -1 变化到 1 的，相比于 Heaviside 函数，它的变化是其两倍，然后乘以 θ 前的系数 -1。如果要严谨地说，也可以认为 $\psi(x,\theta) = 2H(x-\theta)-1$，从这个意义上来看会更清晰一点。不过无论怎么说，我们还是把期望的积分式用 Dirac Delta 写出来了。

$$\mathbb{E}\left[\frac{d}{d\theta}\psi(X,\theta)\right] = -2\int_{-\infty}^{\infty} \delta(x-\theta)f(x)dx$$

实际上，这个积分只在 $x=\theta$ 附近有意义。因此，我们可以只考虑 $[\theta-\epsilon, \theta+\epsilon]$ 上的积分：

$$-2\int_{-\infty}^{\infty} \delta(x-\theta)f(x)dx = -2f(\theta)\int_{\theta-\epsilon}^{\theta+\epsilon} \delta(x-\theta)dx = -2f(\theta)$$

解答 1.4.1

$$\mathbb{E}\left[\frac{d}{d\theta}\psi(X,\theta)\right] = -2f(\theta)$$

“好神奇的函数，跟之前见过的都不一样。”

这样的函数称为‘广义函数’，它具有常规函数不具有的诸多性

质。Dirac Delta 还有更多的性质。

$$\delta(-t) = \delta(t)$$

$$\delta(at) = \frac{1}{|a|}\delta(t)$$

$$\int_{-\infty}^{\infty} \delta'(t - t_0) f(t) dt = -f'(t_0)$$

1.5 不确定性的未来

图书馆的闭馆时间到了，我们离开了图书馆，走在回家的路上。

“有想好选什么学校了吗?”我问泰朵拉。

“想要和学长去同一所大学！专业的话，还是想学计算机。数学或者英语也可以”

泰朵拉的英语一直都很好。

“小理纱呢？有没有什么打算?”

“不要加‘小’。”理纱瞪了我一眼，随后陷入了长久的沉默。

……

“理纱想要学计算机吗?”泰朵拉率先打破了沉默。

“嗯，算法，喜欢。”

“理纱写程序很厉害呢，肯定没问题的。”

我们就这样有一搭没一搭地边走边聊，直到在路口道别。

在数学和科学的发展史上，希尔伯特式的确定与完备一直以来不断地丧失，哥德尔不完备定理更是为我们曾经仰赖的 ZFC 公理和皮亚诺公理的完备性判了死刑；牛顿的机械论世界也被量子力学的不确定性规律所击溃。

米尔嘉，已经开始在美国学习数学；泰朵拉和理纱，也将通过自己的努力踏上自己理想的道路。在这一过程中，没有一条确定性的公式和规律，唯有基于统计与不确定性的经验规律。

而“我”的未来，也必然要在这一不确定性的世界中创造。

第 2 章

参数估计

2.1 最大似然估计

“哥哥，这道掷硬币怎么和之前做的不太一样喵?”

问题 2.1.1

有两枚硬币，硬币 A 是均匀的，硬币 B 掷出正面（H）的概率为 0.75。现在花子取其中一枚硬币抛掷 10 次，得到了以下结果：

HHTHTTHTHH

问：花子取到的硬币是哪枚的可能性更大?

尤里是我的表妹，现在上高一。

“你觉得跟之前做的不一样，是哪里不一样呢?”

“之前米尔嘉大人做的时候，都是先知道了硬币的概率分布，再来推断结果；现在怎么反过来了喵?”

“这是观点的不同。之前的掷硬币问题是概率论的观点：从总体的概率分布出发来推断样本的分布；现在的问题是统计学的观点：从样本的分布来推断总体的概率分布。

“比如说，原本的问题是给定 x，研究 $y = f(x)$ 的性质；现在就变成了给定 y，研究 x 的可能取值了。”

“原来是这样喵，那要怎样做呢?”

⊙ ⊙ ⊙

我们假设事件 A 表示选中 A 硬币，事件 B 表示选中 B 硬币。用 $X = \text{HHTHTTHTHH}$ 表示给定的样本。那么，实际上我们就是要比较条件概率 $P(X|A)$ 和 $P(X|B)$ 的大小。

$$P(X|A) = 0.5^{10} \approx 0.000976$$
$$P(X|B) = (0.75)^6 \cdot (0.25)^4 \approx 0.000695$$

由于 $P(X|A) > P(X|B)$，选中 A 硬币的可能性更大。

解答 2.1.1

花子取到 A 硬币的可能性更大。

“可是，条件概率表示的不是样本出现的概率吗? 如果要求总体的概率，不是应该反过来，写成 $P(A|X)$ 和 $P(B|X)$ 的形式喵?”

我们之前做的 $P(X|A)$ 和 $P(X|B)$ 称为似然概率，它表示的是在给定总体参数的情况下当前样本出现的概率；而 $P(A|X)$ 和 $P(B|X)$ 称为后验概率，它们之间的关系可以通过贝叶斯公式给出：

$$P(A|X) = \frac{P(A)P(X|A)}{P(X)}$$
$$P(B|X) = \frac{P(B)P(X|B)}{P(X)}$$

公式中的 $P(A)$ 和 $P(B)$ 称为先验概率，因为题中没有告诉我们花子是怎么选的，也就是说我们在没有相关的“经验”的前提下，应该认同 $P(A) = P(B) = \frac{1}{2}$ 的先验概率。这样，后验概率的比较就可以转化为似然概率的比较了。

“‘先验’‘后验’‘似然’，好多新的数学概念，要绕晕了喵。”

这里的“先验”，英文叫 prior，就是优先的意思。它“优先”于我们观测到的样本结果，而“后验”（posterior）是我们在接受了观测样本之后对先验概率做出的修正后概率。“似然”（likelihood）是一种反向的概率，它将观测样本作为结果，而将总体的待求参数作为原因。

“原来是这样喵，数学家发明了好多词来命名呢。”

为了严谨表达数学定义，数学家不得不采用越来越多的词汇来准确地指明相应的概念。同时，似然概率的提出还产生了一种重要的方法：最大似然估计。

问题 2.1.2

有一枚硬币，其抛出正面朝上（H）的概率为 θ。现在抛掷这枚硬币 10 次，得到以下结果：

$$\text{HHTHTTHTHH}$$

问：当 θ 为多少时，出现这一试验结果的概率 $P(X|\theta)$ 最大?

“这里的概率就是似然概率喵，所以最大化似然概率就是最大似然估计?”

完全正确！我们要最大化的就是似然概率 $L(\theta;X) = P(X|\theta)$。如果把似然概率写出来，那么就是这样：

$$L(\theta;X) = \theta^6(1-\theta)^4$$

接下来的任务，就是利用函数的知识求它的最大值了。我们可以对似然概率取对数：

$$\ln L(\theta;X) = 6\ln\theta + 4\ln(1-\theta)$$

为了求这个函数在 $\theta \in [0,1]$ 上的最大值，我们可以对其求导：

$$\frac{\partial}{\partial\theta}\ln L(\theta;X) = \frac{6}{\theta} - \frac{4}{1-\theta}$$

当 $\theta = 0.6$ 时，$\frac{6}{\theta} - \frac{4}{1-\theta} = 0$。也就是说，此时的似然概率最大。

解答 2.1.2

当 $\theta = 0.6$ 时，出现试验结果 $P(X|\theta)$ 的概率最大。

这一答案也可以写成 $\hat{\theta}_{MLE} = 0.6$。

我们刚刚通过试验结果（样本）推测总体（参数）的做法称为参数估计，最大似然估计就是参数估计的一种最为重要的估计方法。

“θ 头顶上戴的小帽子是什么意思喵?”

对于一个参数，头顶戴帽子表示它是一个估计量，也就是基于样本数据得到的量。MLE 表示 Maximum Likelihood Estimation，体现了我们采用的估计方法。由于我们得到的估计量是一个点，所以这种估计属于点估计。

◎ ◎ ◎

“高中数学好深奥喵，”尤里伸了个懒腰，“有那么多定义和概念，还有那么多奇怪的符号。”

“高中数学是变难挺多了，不过之前跟米尔嘉在一起的时候讨论的数学，应该也不比这简单多少吧?”

“要是米尔嘉大人在的话，该多好啊。呐，哥哥是不是也很想米尔嘉大人喵?”

……

我对米尔嘉，到底是怎样的情感呢?

2.2 偏差与方差

“哥哥，为什么样本方差要除以 $n-1$ 喵?”尤里指着参考书问。

问题 2.2.1

独立同分布样本 $X_1, \cdots, X_n \sim \mathcal{N}(\mu, \sigma^2)$。为了估计总体方差 σ^2，应该采用什么统计量？

“可以从反面想一想，如果除以 n 而不是 $n-1$，会产生什么结果呢？”

$$\frac{1}{n}\sum_{i=1}^{n}(X_i - \bar{X})^2$$

“嗯……$\sum$ 是求和符号，$\bar{X}$ 表示 X 的平均数，所以这个式子可以展开来写。”尤里开始奋笔疾书。

$$\begin{aligned}\frac{1}{n}\sum_{i=1}^{n}X_i^2 - \frac{2}{n}\bar{X}\sum_{i=1}^{n}X_i + \frac{1}{n}\bar{X}^2 &= \frac{1}{n}\sum_{i=1}^{n}X_i^2 - 2\bar{X}^2 + \bar{X}^2 \\ &= \frac{1}{n}\sum_{i=1}^{n}X_i^2 - \bar{X}^2\end{aligned}$$

“平方的平均减去平均的平方，这样有什么问题喵？”

⊙ ⊙ ⊙

我们刚刚得到了一个“无修正样本方差”，它是一个统计量，也就是说它是样本的函数。现在，我们来求一求这个统计量的期望。

“统计量难道不是一个常数吗？”

这里的期望并不是指把样本看作常数而求出的期望，而是指把样本看作随机变量而求出的期望。由于我们不知道总体的真实分布，所以在这个期望的表达式中，必然会出现未知参数，因此我们用 $\mathbb{E}_\theta$

来表示这个期望，其中 θ 就是指总体的未知参数。在这里，θ 包含 μ、σ^2 两个参数。

$$
\begin{aligned}
\mathbb{E}_\theta\left[\frac{1}{n}\sum_{i=1}^{n}X_i^2-\bar{X}^2\right] &= \frac{1}{n}\sum_{i=1}^{n}\mathbb{E}_\theta[X_i^2]-\mathbb{E}_\theta[\bar{X}^2] \\
&= \frac{1}{n}\sum_{i=1}^{n}(Var(X_i)+(\mathbb{E}_\theta[X_i])^2)-\frac{1}{n^2}\mathbb{E}_\theta\left[\left(\sum_{i=1}^{n}X_i\right)^2\right] \\
&= \frac{1}{n}\cdot n(\sigma^2+\mu^2)-\frac{1}{n^2}\mathbb{E}_\theta\left[\left(\sum_{i=1}^{n}X_i\right)^2\right] \\
&= \sigma^2+\mu^2-\frac{1}{n^2}\left(Var\left(\sum_{i=1}^{n}X_i\right)+\left(\mathbb{E}_\theta\left[\sum_{i=1}^{n}X_i\right]\right)^2\right) \\
&= \sigma^2+\mu^2-\frac{1}{n^2}(n\sigma^2+(n\mu)^2) \\
&= \frac{n-1}{n}\sigma^2
\end{aligned}
$$

我们可以看出，“无修正样本方差”的期望并不等于总体方差 σ^2，所以在样本方差的计算中，我们只需在此基础上乘以 $\frac{n}{n-1}$ 就可以得到参考书上的修正样本方差。

$$
s^2=\frac{n}{n-1}\cdot\frac{1}{n}\sum_{i=1}^{n}(X_i-\bar{X})^2=\frac{1}{n-1}\sum_{i=1}^{n}(X_i-\bar{X})^2
$$

解答 2.2.1

采用修正样本方差

$$s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \bar{X})^2$$

作为 σ^2 的估计量。

“修正之后的样本方差更好，是因为它的期望正好等于总体方差吗?”

没错，s^2 更好的原因是它的无偏性，也就是偏差 $\mathbb{E}_\theta[s^2]-\sigma^2 = 0$。

“原来如此，对局部正确的东西不一定对全局正确喵。”

⊙ ⊙ ⊙

作为 σ^2 的估计量 s^2，我们来讨论 s^2 的方差。

“方差的方差，那是什么?”

这里的 “方差”，不是指样本相对于自身均值的离散程度，而是指估计量相对自身期望的离散程度，具体而言，是这样的：

$$Var(s^2) = \mathbb{E}_\theta[(s^2 - \mathbb{E}_\theta[s^2])^2]$$

换句话说，我们不能把 s^2 看作是一个常量，而应该把它看作一个随机变量，其取值由 $X_1, \cdots, X_n$ 决定。

$$s^2 = \frac{1}{n-1}\sum_{i=1}^{n}X_i^2 - \left(\frac{1}{n-1}\sum_{i=1}^{n}X_i\right)^2$$

我们可以对 s^2 做以下变形：

$$Q = \frac{(n-1)s^2}{\sigma^2} = \frac{1}{\sigma^2}\sum_{i=1}^{n} X_i^2 - \frac{1}{(n-1)\sigma^2}\left(\sum_{i=1}^{n} X_i\right)^2$$

这里的 $Q \sim \chi^2_{n-1}$ 实际上服从自由度为 $n-1$ 的卡方分布，即使不理解也没有关系，我们只要知道 Q 具有期望 $n-1$ 和方差 $2(n-1)$ 就可以了，这是卡方分布的性质。

这样，我们就可以求出 s^2 的方差了。

$$Var(s^2) = Var\left(\frac{\sigma^2 Q}{n-1}\right) = \frac{\sigma^4 \cdot 2(n-1)}{(n-1)^2} = \frac{2\sigma^4}{n-1}$$

对于样本，我们说方差的平方根是标准差，而对于估计量来说，方差的平方根称为标准误。

$$std(s^2) = \sqrt{Var(s^2)} = \sqrt{\frac{2\sigma^4}{n-1}} = \frac{\sqrt{2}\sigma^2}{\sqrt{n-1}}$$

◎ ◎ ◎

“方差的方差，好复杂喵，还用到了没听过名字的分布。”

“数学家就是为了解决这样那样的实际问题，才创造出了这么多分布的。即使暂时没学过也没关系，学习是一个循序渐进的过程。只要小尤里肯认真学，也会变得和米尔嘉学姐一样优秀的。”

“嗯！要变得像米尔嘉大人一样聪明喵。”

2.3　均方误差

“哥哥，既然估计量具有偏差和方差，那应该用哪一个量来衡量估计量的好坏呢?”

$$\mathrm{bias}(\hat{\theta}) = \mathbb{E}_\theta[\hat{\theta}] - \theta$$
$$\mathrm{Var}(\hat{\theta}) = \mathbb{E}_\theta[(\hat{\theta} - \mathbb{E}_\theta[\hat{\theta}])^2]$$

“这两者都是估计量好坏的凭据。以前的统计学家一直执着无偏估计，也就是偏差为 0 的情况下尽可能缩小方差，但现在这一执念也在不断变化。”

⊙　⊙　⊙

“偏差”是估计量的期望相对于真实值的差距，而“方差”是估计量自身的离散程度。现在，常常把两者结合来使用，形成均方误差。

$$\mathrm{MSE}(\hat{\theta}) = \mathbb{E}_\theta[(\hat{\theta} - \theta)^2]$$

这里的 MSE 是 Mean Square Error 的意思。

“为什么说它是把两者综合起来了喵?”

在均方误差中，它既考虑到了估计量离真实值的差距，也考虑到了估计量自身的离散程度。不过，从数学上还能推导出一个重要的关系，称为 Bias-Variance Tradeoff。

问题 2.3.1

证明：$\mathrm{MSE}(\hat{\theta}) = \mathrm{bias}(\hat{\theta})^2 + \mathrm{Var}(\hat{\theta})$。

“那就是要把均方误差的式子展开……”

$$\begin{aligned}
\mathrm{MSE}(\hat{\theta}) &= \mathbb{E}_\theta[(\hat{\theta} - \theta)^2] \\
&= \mathbb{E}_\theta[\hat{\theta}^2] - 2\theta\mathbb{E}_\theta[\hat{\theta}] + \theta^2 \\
&= (\mathrm{Var}(\hat{\theta}) + (\mathbb{E}_\theta[\hat{\theta}])^2) - 2\theta\mathbb{E}_\theta[\hat{\theta}] + \theta^2 \\
&= \mathrm{Var}(\hat{\theta}) + ((\mathbb{E}_\theta[\hat{\theta}])^2 - 2\theta\mathbb{E}_\theta[\hat{\theta}] + \theta^2) \\
&= \mathrm{Var}(\hat{\theta}) + (\mathbb{E}_\theta[\hat{\theta}] - \theta)^2 \\
&= \mathrm{Var}(\hat{\theta}) + \mathrm{bias}(\hat{\theta})^2
\end{aligned}$$

尤里做得很棒，不过还有一种更简单的方法。

解答 2.3.1

$$\begin{aligned}
\mathrm{MSE}(\hat{\theta}) &= \mathbb{E}_\theta[(\hat{\theta} - \theta)^2] \\
&= \mathbb{E}_\theta[((\hat{\theta} - \mathbb{E}_\theta[\hat{\theta}]) + (\mathbb{E}_\theta[\hat{\theta}] - \theta))^2] \\
&= \mathbb{E}_\theta[(\hat{\theta} - \mathbb{E}_\theta[\hat{\theta}])^2] + 2(\mathbb{E}_\theta[\hat{\theta}] - \theta)\mathbb{E}_\theta[(\hat{\theta} - \mathbb{E}_\theta[\hat{\theta}])] \\
&\quad + (\mathbb{E}_\theta[\hat{\theta}] - \theta))^2 \\
&= \mathrm{Var}(\hat{\theta}) + 0 + \mathrm{bias}(\hat{\theta})^2 \\
&= \mathrm{Var}(\hat{\theta}) + \mathrm{bias}(\hat{\theta})^2
\end{aligned}$$

“为什么中间的交叉项变成 0 了喵?”

考虑 $\mathbb{E}_\theta[(\hat{\theta} - \mathbb{E}_\theta[\hat{\theta}])] = \mathbb{E}_\theta[\hat{\theta}] - \mathbb{E}_\theta[\mathbb{E}_\theta[\hat{\theta}]]$，其实第二项的外层期望求解时里面已经是常数 $\mathbb{E}_\theta[\hat{\theta}]$ 了，两个相等的常数相减，自然就得到 0 了。

“Tradeoff，是权衡的意思喵？那就是说如果均方误差一定，偏差和方差是此消彼长的关系?”

完全正确。Bias-Variance Tradeoff 定量解释了偏差和方差的关系，同时也启示统计学家在参数估计中，应该合理选取估计方法，让偏差和方差达到合理的状态。

⊙　⊙　⊙

短暂的假期结束了，紧接着便是期中考试。

和高中不一样，大学的期中考试并没有为高考[①]之类的考试负责的必要，是教授根据所授课程的情况自己出题的考试。所幸自己上课还是听了一点，分数还看得过去。

当我看到那些熟悉的数学符号的时候，当我解出一道看似不可解的问题时，那种欢欣和鼓舞，总是令我回想起高中那段与朋友一起讨论数学的经历。

选择了自己喜欢的学校，喜欢的专业，还能继续学习更高深的数学，这不应该是多么值得庆幸的一件事吗?

只不过，总感觉缺失了些什么。

好像哥德尔不完备定理中的 $\mathrm{sub}(\mathfrak{n}, \mathfrak{n}, 17)$，它的缺失不影响在这套公理基础上的进一步构建；好像伽罗瓦理论对五次方程求根公式不存在的宣判，它的缺失不影响用数值方法对高次方程的求解；

[①] 日本大学录取制度与中国存在一定区别，此处“高考”表述系遵循人民邮电出版社翻译结城浩原作时的用语惯例。

好像那樱花树下不再有那个少女，但樱花树还是那棵樱花树，继续蓬勃地绽放。

那么，这缺失的到底是什么呢?

2.4 置信区间

我又做梦了，梦到了高中的某个午后。

问题 2.4.1

掷一枚硬币 10 次，得到实验结果：恰有 k 次正面朝上。假设硬币每次正面朝上的概率是固定值 θ，求 θ 的区间估计。

高中的图书馆，我，米尔嘉，泰朵拉。

很有意思，这是一场“清醒梦”：我保有我现在的意识和记忆，完全明白这是一场梦，但我不愿醒来。

我不愿意。

现在是米尔嘉的主场，我保持缄默。

⊙ ⊙ ⊙

掷 10 次硬币，硬币正面朝上的次数服从 $B(10,\theta)$ 的分布。根据实验结果，我们得出了 θ “最有可能”的取值 $\hat{\theta}=\frac{k}{10}$。

但是，即使 $\theta\neq\frac{k}{10}$，我们也有可能得到当前的实验结果。因此，我们对 θ 的估计不应该只是一个点，而应该是一个区间。在这个区间中，靠近 k 的可能性更大，而远离 k 的可能性更小。

“θ 是一个……区间?”

没错，这样的区间称为置信区间。以 95% 置信区间为例，如果我们每次都扔 10 次，每次都构造一个 95% 置信区间，那么，在这

些区间中，有 95% 的区间会包含 θ 的真实值。

$$P(\theta \in CI) = 0.95$$

“这是在说，真实的 θ 有 95% 的概率落在置信区间中吗?”

这样说不准确，因为 θ 是确定的，而置信区间才是随机的。它表示的不是关于 θ 的概率命题，而是关于区间的概率命题。

我们需要讨论 $\hat{\theta}$ 的方差和标准误。

“标准误?”

是的，名字和标准差很相似，只不过标准差通常针对样本，而标准误通常针对估计量。为了构造置信区间，我们需要知道估计量本身相对于自身均值的离散程度。

考虑独立同分布样本 $X_1, \cdots, X_{10} \sim Ber(\theta)$，我们采用估计量 $\hat{\theta} = \bar{X}$，接下来，我们来讨论 $\hat{\theta}$ 的方差和标准误。

$$\begin{aligned} Var(\hat{\theta}) &= Var\left(\frac{X_1 + \cdots + X_{10}}{10}\right) \\ &= \frac{1}{100} Var(X_1 + \cdots + X_{10}) \\ &= \frac{1}{100} \cdot 10 Var(X_1) \\ &= \frac{Var(X_1)}{10} \\ &= \frac{\theta(1-\theta)}{10} \end{aligned}$$

相应的，标准误 $std(\hat{\theta}) = \sqrt{Var(\hat{\theta})} = \sqrt{\frac{\theta(1-\theta)}{10}}$。但是，我们实际上并不知道 θ 的真实值，所以只能使用 $\hat{\theta}$ 代替式中的 θ，得到更

为常用的经验标准误：

$$\hat{\text{std}}(\hat{\theta}) = \sqrt{\frac{\hat{\theta}(1-\hat{\theta})}{10}}$$

根据中心极限定理，我们认为参数估计量 $\hat{\theta}$ 近似服从正态分布 $\mathcal{N}(\hat{\theta}, \hat{\text{std}}(\hat{\theta}))$，并可据此得到 95% 置信区间。

$$\text{WaldCI} = \hat{\theta} \pm \hat{\text{std}}(\hat{\theta}) z_{\alpha/2}$$

“这里的 α 和 $z_{\alpha/2}$ 是什么意思呢?”

$\alpha = 0.05$ 代表显著性水平，我们实际上在求的是 $1-\alpha$ 置信区间，从而要排除掉正态首尾两端各 $\alpha/2$ 的概率值。$z_{\alpha/2} = \Phi^{-1}(1-\alpha/2)$ 就是帮助我们实现这一点的。

代入我们的估计量，得到 $\hat{\theta} = \frac{k}{10}$ 和 $\hat{\text{std}}(\hat{\theta}) = \sqrt{\frac{\frac{k}{10}(\frac{1-k}{10})}{10}} = \frac{\sqrt{k(1-k)}}{10\sqrt{10}}$。

问题 2.4.1

θ 具有 95% 置信区间 $\frac{k}{10} \pm \frac{\sqrt{k(1-k)}}{10\sqrt{10}}$。

这个区间的含义是，如果我们反复做“掷硬币 10 次”的试验，并每次都用这样的方式构造出相应的置信区间，则大约有 95% 的区间包含了 θ 的真实值。

2.5 硬币公平吗

那么，当 k 为多少时，才能说这个硬币不公平呢?

“如果 k 很大或者很小，就可以说这个硬币不公平了吧。”

我们实际上正在做关于硬币公平性的“假设检验”，考虑以下两个假设：

$$H_0：硬币公平$$

$$H_1：硬币不公平$$

泰朵拉，假如有人做了试验发现 $k = 6$，于是就认为硬币不公平，你认为他的结论靠谱吗？

“一点也不靠谱！即使硬币公平，也很有可能出现 $k = 6$ 的情形啊。”

没错，他的错误在于在不应该抛弃 H_0 的情况下抛弃了 H_0，这称为第一类错误。那如果有人发现 $k = 10$，但还是认为硬币公平，你认为他的结论靠谱吗？

“嗯……即使硬币公平，也不是没有可能出现 $k = 10$ 的情况，但是这个概率微乎其微啊。”

是的，他的错误在于在应该抛弃 H_0 的情况下没有抛弃 H_0，这称为第二类错误。任何假设检验的结果都有可能犯这两种错误中的一种，只是犯错误概率大小的分别。假如第二个人在 $k = 10$ 时抛弃了 H_0，那么他仍然有很小的概率犯第一类错误；假如第一个人在 $k = 6$ 时保留了 H_0，那么他仍然有一定的概率犯第二类错误。换言之，不管他们怎么做，总是有犯错误的可能性。

“难道不存在百分之百正确的假设检验吗？”

假设检验总是存在犯错误的可能性的。通常情况下，我们是在“犯第一类错误的概率不超过某一常数”的前提下，讨论能否拒绝

H_0。这里的常数，就是显著性水平 α。

当零假设成立时，将 $\theta = 0.5$ 代入置信区间的表达式，得到以下 95% 置信区间：

$$(0.19, 0.81)$$

也就是说，如果硬币正面朝上的均值不落在其中，即在 1 次以下或在 9 次以上（含端点），则可以在犯错误概率不超过 0.05 的条件下拒绝 H_0，认为硬币“不公平”。

实际上，我们刚刚在构造置信区间时使用了近似方法。现在，让我们用二项分布的精确值重新讨论这一问题。

问题 2.5.1

掷一枚硬币 10 次，得到实验结果：恰有 k 次正面朝上。当 k 为多少时，可以在 $\alpha = 0.05$ 的显著性水平下否认 H_0，即认为硬币“不公平”（使用二项分布的精确结果）?

“假如硬币是公正的，那么出现 k 次正面朝上的概率应该要用组合数来写吧。”

$$\binom{10}{k} 0.5^k 0.5^{10-k} = \binom{10}{k} 0.5^{10}$$

“也就是说，k 值应该满足这一条件。”

$$\binom{10}{k} 0.5^{10} < \alpha$$

不对哦，左边应该是“在零假设成立时，出现 k 次或者更糟糕

结果”的概率，这一概率也称为 p 值。

因此，相应的不等式可以这样写。由于二项式系数的对称性，我们只需讨论一边即可。

$$\sum_{i=0}^{k} \binom{10}{i} 0.5^{10} < \alpha$$

解这个不等式，得到 $k \leqslant 1$。由对称性可得，$k \geqslant 9$ 也应该满足要求。这一结果与之前用 Wald 近似得到的结果是一致的。

解答 2.5.1

当 $k \leqslant 1$ 或 $k \geqslant 9$ 时，可以在 $\alpha = 0.05$ 的显著性水平下认为硬币不公平。

“原来是这样，看来 p 值是个很重要的量呢。”

是的，在假设检验的步骤中，我们就是将当前样本或更糟糕样本的概率 p 值与显著性水平 α 做比较，来确定是否能否认原假设的。

假设检验的步骤：

- 写出零假设（H_0）和备择假设（H_1），确定显著性水平 α；
- 计算在零假设成立的前提下当前样本或更糟糕样本出现的概率 p 值；
- 比较 p 值与 α，如果 $p < \alpha$，则否认零假设并接受备择假设（犯第一类错误的概率不超过 α），否则保留零假设（仍有犯第二类错误的概率）。

第 3 章

多元统计与回归分析

3.1 协方差

突然间，我感到一阵震动。

身边的这一切事物突然在一瞬间暗淡下来，阳光在空中划出了一道口子。

清脆的铃声响起，我明白，这是闹钟的铃声，现实世界在召唤我返回。

“要走了吗？那么，祝你好运。”

这是我醒来之前，梦中的米尔嘉说的最后一句话。

人不可能永远活在梦中，就像现实世界的随机变量不可能永远是一元的一样。

我们面对着大量的变量，研究这些变量之间的联系尤为重要。

统计学是进行决策、把握规律的重要支撑，面对现实的这一复杂性，统计学没有理由不给出自己的回应。

现实的生活必须继续，我没有理由沉溺于过往的温柔乡中停滞不前，如果米尔嘉知道我是那样的人的话，也一定会讨厌我吧。

我带上笔记本，踏上了前往教室的路途。

⊙　⊙　⊙

今天的内容不多，完成作业后，我便打开了那个名为“*Eulerians*”的文件夹。

Eulerians 是我们高中的时候创办的数学杂志，目前由于泰朵拉在高三，由我承担主要的撰写工作。这次是多元统计的专题内容，我写下了第一个公式：

$$\mathrm{Cov}(X,Y)=\mathbb{E}[(X-\mathbb{E}[X])(Y-\mathbb{E}[Y])]=\mathbb{E}[XY]-\mathbb{E}[X]\mathbb{E}[Y]$$

协方差是一个并不新鲜的概念，它衡量的是两个随机变量的“协变性”：一个随机变量变化时，另一个随机变量的“变化趋势”。单个随机变量的方差其实就是协方差的一种特殊情形：

$$\mathrm{Cov}(X,X)=\mathrm{Var}(X)=\mathbb{E}[X^2]-(\mathbb{E}[X])^2$$

独立性蕴涵协方差为 0，但协方差为 0 不蕴涵独立性，协方差捕捉的只是“线性”的相关关系。

嗯，这样作为背景知识应该足够了。

⊙　⊙　⊙

“学长，我还是不理解为什么协方差只捕捉线性关系。”

这里好像确实比较抽象，可以加一点例子。示例是理解的试金石，米尔嘉是这样说的。

（为什么我老是提起米尔嘉呢？也是统计相关性？）

问题 3.1.1

考虑随机变量 $\theta \sim U(0, 2\pi)$ 服从 0 到 2π 的均匀分布，$X = \cos\theta$ 且 $Y = \sin\theta$，求 $Cov(X, Y)$。

我们可以分别计算 $\mathbb{E}[XY]$、$\mathbb{E}[X]$ 和 $\mathbb{E}[Y]$，并利用这些结果得到 $Cov(X, Y)$。

$$\mathbb{E}[XY] = \int_0^{2\pi} \sin\theta\cos\theta \cdot \frac{1}{2\pi} d\theta = 0$$

$$\mathbb{E}[X] = \int_0^{2\pi} \cos\theta \cdot \frac{1}{2\pi} d\theta = 0$$

$$\mathbb{E}[Y] = \int_0^{2\pi} \sin\theta \cdot \frac{1}{2\pi} d\theta = 0$$

根据公式，很容易可以算出其协方差为 0。

解答 3.1.1

$$Cov(X, Y) = 0$$

但是显而易见，X 和 Y 不是独立的。相反，它们处在一个以原点为圆心的定圆上，而这样的关系没办法为协方差所捕捉。

“原来是这样，加了例子瞬间就懂了，谢谢学长!”

3.2 条件分布

协方差只能捕捉线性的关系，所以引入联合分布是必要的。

把累积分布函数稍加修改，就可以得到联合分布函数：

$$F(x,y) = P(X \leqslant x, Y \leqslant y)$$

假如 $F(x,y)$ 性质良好，还可以求出联合密度：

$$f(x,y) = \frac{\partial^2}{\partial x \partial y} F(x,y)$$

若讨论其中某一个变量的分布情况，可以使用边缘分布：

$$F_X(x) = P(X \leqslant x) = F(x,\infty)$$

或者，使用边缘密度：

$$f_X(x) = \int_{-\infty}^{\infty} f(x,y)dy$$

嗯，这样的话就比较完整了，之后的内容还是讨论一下为好。

⊙ ⊙ ⊙

数学与应用数学夏令营，不仅跨校跨年段，高中生也能参加？有意思。

等下，合作学校里面，还有米尔嘉所在的那所美国大学？

这倒是可以跟泰朵拉她们商量一下，说不定能够给 *Eulerians* 一点启发，说不定还能获得米尔嘉的帮助。

说实在的，现在的数学对我来说已经有些吃力了，如果能够获

得才女米尔嘉的帮助，对于 *Eulerians* 的发展一定有不少帮助。

只不过，她还会乐意和我们玩这种过家家的游戏吗？

尽管有这样的顾虑，我还是把我的提议告诉了泰朵拉和理纱。

“感觉好有趣的样子！又能够一起讨论数学了呢，还能认识更多的人。”泰朵拉对我的提议赞不绝口。

“或许可以和 *Eulerians* 一同进行。”理纱像是读懂了我的想法似的。

“不过如果这样的话，可不可以邀请米尔嘉学姐一起来？”

她们跟我一样，都没有忘记。

我们的故事，还将由我们自己继续书写。

不过，眼下还是要完善一下 *Eulerians* 的内容。

⊙ ⊙ ⊙

我还想再写一些和条件分布相关的内容。

“条件分布，那是什么？”

当一个随机变量的分布与另一个随机变量相关时，就形成了条件分布，比如下面就是一个条件分布：

$$X|Y = y \sim \mathcal{N}(y, 1)$$

它表示：当 $Y = y$ 时，X 服从 $\mathcal{N}(y, 1)$ 的正态分布。而由于 Y 本身也是一个随机变量，这里就会引出很多有意思的问题。

比如，我们可以考虑条件密度 $f_{X|Y}(x|y) = \phi(x - y)$，它表示在 $Y = y$ 的条件下，$f_X(x)$ 的密度值。

如此，我们可以定义条件期望值 $\mathbb{E}[X|Y = y]$，它的定义很简单：

$$\int_{-\infty}^{\infty} x f_{X|Y}(x|y)dx$$

对于性质良好的函数，我们有以下关系成立：

$$f_{X|Y}(x|y) = \frac{f(x,y)}{f_Y(y)}$$

正态分布的期望就是 μ，所以相应的条件期望 $\mathbb{E}[X|Y=y]=y$。有些时候，条件分布中的条件形式会比较复杂。

问题 3.2.1

考虑条件分布 $X|Y=y \sim \mathcal{N}(y,1)$，$Y \sim U(0,1)$，求 $\mathbb{E}[X|Y>k]$，其中 $k \in (0,1)$。

“在 $Y>k$ 的条件下，求 X 的期望，那就是说 $Y \sim U(k,1)$，而 X 是 Y 的函数咯?”

X 的分布是 Y 的函数，但 X 本身不是 Y 的函数。在我们之前的推导中，已经有了 $\mathbb{E}[X|Y=y]=y$。接下来，让我们重写题中的期望：

$$\begin{aligned}
\mathbb{E}[X|Y>k] &= \frac{1}{1-k}\int_k^1 \mathbb{E}[X|Y=y]dy \\
&= \frac{1}{1-k}\int_k^1 y dy \\
&= \frac{1}{1-k}\cdot\frac{1^2-k^2}{2} \\
&= \frac{1+k}{2}
\end{aligned}$$

解答 3.2.1

$$\mathbb{E}[X|Y > k] = \frac{1+k}{2}$$

“这里的期望，就是对 $\mathbb{E}[X|Y = y]$ 关于每一种可能的 y 取平均吗?”

可以这么理解，要注意这里的平均是对 Y 取每一种值的概率加权平均，也就是说：

$$\mathbb{E}[X|Y \in S] = \frac{1}{P(Y \in S)} \int_S f_Y(y)\mathbb{E}[X|Y = y]dy$$

因此，如果我们不加约束地写出 $\mathbb{E}[X|Y]$，实际上我们并不能得到一个具体的期望值，而是得到了一个函数。当我们对于 Y 附加具体的条件的时候，我们才能够得到传统理解意义上的“期望”。

由 Y 生成的所有“信息”的集合，记作 $\sigma(Y)$。之前的信息 $Y = y$、$Y > k$ 等等，都是 $\sigma(Y)$ 中的元素。相应的，$\mathbb{E}[X|Y]$ 也可以写成 $\mathbb{E}[X|\sigma(Y)]$。

我们来整理一下到目前为止，条件分布的“旅行地图”：

- 定义联合分布和边缘分布，进而得到联合密度和边缘密度 $f(x,y)$ 和 $f_X(x)$、$f_Y(y)$；
- 利用联合密度和边缘密度，定义条件分布密度：$f_{X|Y}(x,y) = \frac{f(x,y)}{f_Y(y)}$（类比条件概率 $P(A|B) = \frac{P(AB)}{P(B)}$）；
- 定义特殊形式的条件期望 $\mathbb{E}[X|Y = y] = \int_{-\infty}^{\infty} x f_{X|Y}(x,y)dx$；

- 将条件一般化，得到 $\mathbb{E}[X|Y \in S]$ 形式的条件期望，进而引入 $\mathbb{E}[X|\sigma(Y)]$ 或 $\mathbb{E}[X|Y]$。

“感觉这次的‘旅行地图’有点奇怪。”

的确，因为我们先定义了极为特殊的条件期望，然后才推广到一般形式的条件期望。在现代概率论中，这个顺序是反过来的，也就是先有 σ 代数和基于 σ 代数的 $\mathbb{E}[X|\sigma(Y)]$，再有具体条件下的 $\mathbb{E}[X|Y = y]$。严格的概率论定义，必须以测度论为基础，但这超出了我的能力范围。

不过，解决初等概率论里的问题，以上的定义是足够的。

问题 3.2.2

考虑随机变量 X、Y 和某一观测结果 $Y = y$，求以下关于 a 的优化问题的解：

$$\min_a \mathbb{E}[(X - a)^2|Y = y]$$

这道题的意思是，改变 a 的取值，使得条件期望最小。

期望的线性性质对条件期望同样成立，所以我们可以这样写

$$\begin{aligned}\mathbb{E}[(X - a)^2|Y = y] &= \mathbb{E}[X^2 - 2aX + a^2|Y = y] \\ &= \mathbb{E}[X^2|Y = y] - 2a\mathbb{E}[X|Y = y] + a^2\end{aligned}$$

令 $\mu = \mathbb{E}[X|Y = y]$，$\nu = \mathbb{E}[X^2|Y = y]$，我们就得到了以下关于

a 的二次函数：

$$g(a) = a^2 - 2\mu a + \nu$$

根据二次函数的性质，当 $a = \mu = \mathbb{E}[X|Y = y]$ 时，$g(a)$ 取得最小值。

解答 3.2.2
当 $a = \mathbb{E}[X|Y = y]$ 时，$\mathbb{E}[(X - a)^2|Y = y]$ 取得最小值 $\mathbb{E}[(X - \mathbb{E}[X|Y = y])^2|Y = y] = Var(X|Y = y)$。

“条件方差?”

没错，我们意外得到了条件方差的定义：

$$Var(X|Y = y) = \mathbb{E}[(X - \mathbb{E}[X|Y = y])^2|Y = y] = \mathbb{E}[X^2|Y = y] - (\mathbb{E}[X|Y = y])^2$$

因为条件方差实际上就是一种特殊的条件期望，我们可以利用之前的推广方法，将其定义推广到 $Var(X|\sigma(Y))$ 上。

关于条件期望和方差，有一个有趣的结论：

根据定义，我们有：

$$\begin{aligned}\mathbb{E}[Var(X|Y)] &= \int_{-\infty}^{\infty}(\mathbb{E}[X^2|Y=y]-(\mathbb{E}[X|Y=y])^2)f_Y(y)dy \\ &= \mathbb{E}[X^2]-\mathbb{E}[(\mathbb{E}[X|Y])^2] \\ Var(\mathbb{E}[X|Y]) &= \int_{-\infty}^{\infty}(\mathbb{E}[\mathbb{E}[X|Y]^2|Y=y]-(\mathbb{E}[\mathbb{E}[X|Y]|Y=y])^2)f_Y(y)dy \\ &= \mathbb{E}[(\mathbb{E}[X|Y])^2]-\mathbb{E}[X^2]\end{aligned}$$

将两者相加，我们可以得到全方差公式：

$$Var(X) = \mathbb{E}[Var(X|Y)] + Var(\mathbb{E}[X|Y])$$

直观理解全方差公式，可以理解成一个变量的变异性，既具有每一组内变异性的贡献，也具有组间变异性的贡献。

⊙ ⊙ ⊙

就这样，随着泰朵拉的疑问，我不断完善着 *Eulerians* 的内容。

暑假的日子越来越近，是时候开始着手夏令营的事情了。

因为也包含应用数学的部分，且考虑到参加者以本科生和高中生为主，实际上能够接受的报告种类相当多元。

“米尔嘉学姐也会一起来！”泰朵拉兴奋地告诉我。

太好了，这样不管是夏令营还是 *Eulerians* 都有了坚实的依靠，我也可以稍微缓一缓了。

真是巧啊，数学把相去万余里的我们重新连接在一起。

还记得毕业研讨会上关于黎曼猜想的讨论，除去到现在还没搞明白的复变函数论之外，我记得这样一句话：

“数学，穿越时空。”

这样，*Eulerians* 团队就集齐了。理纱可以写程序模拟，我和米尔嘉可以做主要的数学推演，而泰朵拉可以和尤里一起做相关的辅助工作。

但在那之前，还有一件事：

考试周要到了。

3.3 相关系数与线性回归

在那之前，还是有必要复习一下期末考试的内容。

问题 3.3.1

证明向量形式的柯西不等式：

$$|u \cdot v| \leqslant \|u\|\|v\|$$

并由此证明相关系数

$$\rho = \frac{\frac{1}{n}\sum x_i y_i - \frac{1}{n^2}\sum x_i \sum y_i}{\left(\sqrt{\frac{1}{n}\sum x_i^2 - (\frac{1}{n}\sum x_i)^2}\right)\left(\sqrt{\frac{1}{n}\sum y_i^2 - (\frac{1}{n}\sum y_i)^2}\right)}$$

的范围是 $[-1, 1]$。

证明柯西不等式并不复杂，使用余弦定理即可。而相关系数可以写成这种形式：

$$\rho = \frac{\frac{1}{n}\sum(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\frac{1}{n}\sum(x_i - \bar{x})^2}\sqrt{\frac{1}{n}\sum(y_i - \bar{y})^2}} = \frac{\sum(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum(x_i - \bar{x})^2}\sqrt{\sum(y_i - \bar{y})^2}}$$

这样，我们就可以用向量的语言重新写出相关系数的表达式。

令 $x = (x_i - \bar{x})_{i\in[1,n]}$, $y = (y_i - \bar{y})_{i\in[1,n]}$，相关系数就可以写成以下形式：

$$\rho = \frac{x \cdot y}{\|x\|\|y\|}$$

从而使用柯西不等式证明其范围。

解答 3.3.1

$|u \cdot v| = \|u\|\|v\||\cos\theta| \leqslant \|u\|\|v\|$。

由于 $\rho = \frac{x\cdot y}{\|x\|\|y\|}$，且 $|x \cdot y| \leqslant \|x\|\|y\|$，故 $\rho \in [-1, 1]$。

嗯，期末考试应该问题不大，毕竟占比也不高。

接下来，可以看看 *Eulerians* 和夏令营的事情了。

⊙ ⊙ ⊙

“是打算讲一些应用统计的内容吗？感觉挺有趣的。”

我读着米尔嘉发来的消息。

“想要怎么引入呢，线性回归吗？”

线性回归确实是非常基础的内容。如果从线性回归引入损失函数和优化的概念的话，也就能理解更加复杂的模型了。

具体来说，就是假设总体服从这样的分布：

$$y = wx + b + \epsilon$$

其中，ϵ 是随机误差，其真实值无法为我们得知。在实践中，我们通过样本 $(x_1, y_1), \cdots, (x_n, y_n)$ 进行统计推断，得到回归方程 $y = wx + b$，同时使得残差的平方和，也就是均方误差最小。

理纱可以写程序来演示，她最近刚学了 Scikit-Learn，如果后面要做正则化的也可以。

“可是，如果仅仅是调包，真的能让听众理解原理吗？”

的确，如果仅仅是调用现成的库函数，虽然省力，但对展示原理不是好的选择。我认为可以提供一个 from scratch 的版本，同时提供现在工业界常用的调用库函数的版本。

“嗯，这样就挺好的。最近有教她们一些新的数学吗？”

最近嘛……交了一些新的数学，对，“亿”些。

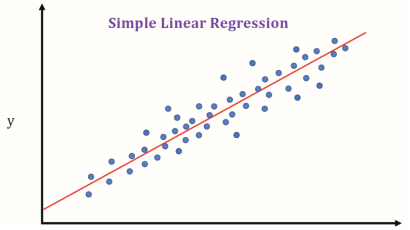
“不要总是甩概念，多启发她们的思维，就像村木老师一样。”

我感觉自己突然变成了青年教师，米尔嘉成了教研组长。

“说不定你会像村木老师一样，成为一名真正的数学老师呢。所以从现在开始，好好练习吧。”

⊙ ⊙ ⊙

我们四个人在图书馆，讨论数学和夏令营的事情。由于米尔嘉还在美国，暂时不能参会。我先展示了这样一张图片。



“regression，是回归的意思吧，”泰朵拉率先发言，“看起来是用一条直线拟合了数据点，那为什么称为‘回归’呢?”

之所以将拟合称为 regression 或者‘回归’，实际上是由历史因素决定的。在 19 世纪的时候，生物学家弗朗西斯·高尔顿发现即使父母身高异常高或矮，子代身高通常也会接近整体均值，这种趋势称为“回归”。高尔顿的“回归”概念引入统计学后，成了一种重要的拟合方法。与插值法不同的是，即使有少数异常值，“回归”也可以得到相对正确的结果。

回归分析是统计中的重要方法，我们可以把它作为 *Eulerians* 的重点内容，也可以作为夏令营上的汇报主题。

如果我们有一堆数据点的话，我们可以画出很多条“看起来很对”的直线。那么，什么样的直线才能在数学上称为是最好的呢?

“用均方误差，是不是就可以了?”尤里说。

不错的，最小化均方误差确实是一种重要的思想。这种方法称为“最小二乘法”，而“二乘”就是平方的意思。具体而言，我们希望最小化以下函数：

$$\mathrm{MSE} = \frac{1}{n}\sum_{i=1}^{n}(wx_i + b - y_i)^2$$

于是，回归问题成功化归为最优化问题。这个最优化问题是有

解析解的，只需要对 w 和 b 分别求偏导，然后令偏导等于 0 即可。

“梯度下降。”理纱说。

对于现实世界更多的函数，我们难以求出解析解，于是通过梯度下降的方式求近似解。所谓“梯度”，其实就是多元函数的一种特殊的导数。

考虑函数 $f(x_1, \cdots, x_n)$，其梯度写作 ∇f：

$$\nabla f = \sum_{i=1}^{n} \frac{\partial}{\partial x_i} \hat{e}_i$$

这里的 $\hat{e}_i$ 是第 i 个方向上的单位向量，所以标量场的梯度实际上是一个矢量场。在之前关于黎曼猜想的讨论中，我们已经详尽地阐释了矢量分析的大多数内容。

在这里，我们就是要利用梯度来更新参数 (w, b)：

$$(w, b) \leftarrow (w, b) - lr \cdot \nabla MSE \cdot (w, b)$$

“这里的 lr 是什么？”

lr 代表 learning rate（学习率），表示每次更新的“步子”大小。这个值太小了会导致速率过慢，太大了可能会导致模型扰动过大，无法达到最优解。

“我们要推断的参数是 w 和 b，并不包括 lr，那这里的 lr 要怎么得到呢？”

像 lr 这样的参数称为超参数，它是我们在问题之外手动引入的参数。调节超参数的过程称为超参数调优，在机器学习领域有更为完善的方法。

“机器学习？是让电脑来学习嘛？”尤里提出了疑惑。

大体正确。机器学习是让电脑来运用统计推断的方法学习数据的特征，而回归正是机器学习中一种重要的任务类型。机器学习还有分类、聚类等等其他任务，不过不管是什么样的机器学习都有坚实的数学和统计学支撑，因此学好相关的数学知识是必要的。

◎ ◎ ◎

```
import pandas as pd
data = pd.read_csv("linear_regression_dataset.csv")
print(data)
def Regression(x,y):
    n = len(x)
    w,b = 1,0
    lr = 0.01
    for epoch in range(50):
        mse = sum((w*x[i]+b-y[i])**2 for i in range(n))/n
        print("Mean Square Error:",mse)
        grad_w = sum(2*(w*x[i]+b-y[i])*x[i] for i in range(n))/n
        grad_b = sum(2*(w*x[i]+b-y[i]) for i in range(n))/n
        w -= lr*grad_w
        b -= lr*grad_b
        print(f"w={w}, b={b}")
Regression(data['x'],data['y'])
```

“这段代码就是做线性回归的嘛?”泰朵拉指着理纱的代码问。

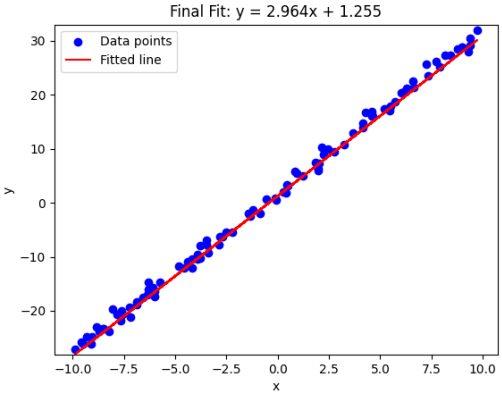
“嗯，用 Python 写的。”

Python 是一种可读性很强的语言，即使没有相关的经验，也可

以很容易地读懂 Python 的代码。

理纱，能够把散点图和线性回归直线生成一下吗？

“嗯。”理纱改起了代码。



可以看出，回归直线对数据集拟合得很好。但是，这不是机器学习的终点。机器学习还要关心模型对于没见过的数据的表现，也就是泛化能力。

“泛化能力？”

对，我们不可能穷尽世界上所有的数据“喂”给模型，但是我们又要利用模型去预测没有见过的数据，这就是问题的复杂之处。为了提升模型的泛化能力，人们提出了各种各样的方法，如果时间来得及，我们可以在解决统计的部分之后加入有关的内容。

“机器学习好有意思啊！”尤里感叹道。

“机器学习和统计学一样吗？”泰朵拉问。

其实不完全一样。机器学习更关心模型在复杂数据上的表现和泛化能力，而统计学更关心模型的可解释性和假设的合理性。两者

使用的很多数学工具是共通的，但在思维方式上存在着显著的区别。

举个最明显的例子，对于样本相关系数，机器学习和统计学都认识到其重要性，但使用它的动机具有明显的不同。

样本相关系数是这样一个值：

$$\rho = \frac{\sum(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum(x_i - \bar{x})^2}\sqrt{\sum(y_i - \bar{y})^2}}$$

对于统计学家来说，它是假设检验的支撑，也为可解释性提供一定依据。统计学家会问，它们“为什么”相关？是否有理论支持？典型的输出是 p 值和置信区间。而对于机器学习来说，它是提升模型预测准确率的工具，不关心是否“真的”相关，常用于特征选择和模型评估辅助等方面。我们可以以这样一个例子来说明：假设我们要预测学生的成绩 Y，有自变量学习时间 X_1 和鞋码尺寸 X_2，并且得到了以下结果：

$$\rho(Y, X_1) = 0.60$$

$$\rho(Y, X_2) = 0.58$$

我们应该如何解释这样的结果？

“学习成绩为什么和鞋码有关系呢？这解释不清楚吧！”尤里率先说。

“嗯……也是有用的信号，可以先留着，提升模型准确率。”理纱提出了不同的意见。

尤里和理纱代表的分别就是统计学和机器学习的观点。在统计

学看来，X_2 是一个干扰变量，除非我们能够解释它（比如鞋码和年龄的混杂），否则我们应该剔除；而在机器学习看来，既然能提升模型的准确度，那就先保留试试看。

“那哪一种观点是对的呢?”泰朵拉问。

这两种观点没有对错之分，它们是看待数据的不同思维方式，都具有重要的意义。近年来，两者也有融合的趋势，比如可解释机器学习引入统计思想，以及也有相应因果推断的方法，结合统计建模和预测能力。在现在的研究中，p 值和相关系数也常常作为机器学习的报告结果，统计分析也经常使用机器学习模型进行预测。

“感觉像两个世界的对话呢。”

没错，一名优秀的数据科学家正是在这两个世界中的穿行者，用统计理解世界，用机器学习预测未来。

◎ ◎ ◎

“今天讨论出来什么新的东西了吗?”

我们打算从统计学和机器学习两个视角来解释现实问题，这样可以比较两种观念的不同，提供一些关于数据科学的哲学思考。

“看来进展很丰富呢。我再过两个星期要回来了，到时候一起讨论吧。”

3.4 随机向量与协方差矩阵

“你线性代数学得怎么样?”

坏了，还没复习，明天就要考试了。

我以要复习为借口，匆匆结束了对话。

问题 3.4.1

已知矩阵

$$A = \begin{bmatrix} 2 & 1 & 3 \\ 3 & 4 & 1 \end{bmatrix}$$

$$B = \begin{bmatrix} 1 & 2 \\ 3 & 4 \\ 5 & 6 \end{bmatrix}$$

求乘积 AB。

矩阵乘法，对于初学者来说可能有一定难度，但熟练后其实就是最简单的计算题。

利用公式：

$$(AB)_{ij} = \sum_{k=1}^{m} A_{ik} B_{kj}$$

很容易可以求出矩阵的乘积。

$$AB = \begin{bmatrix} 2\cdot 1 + 1\cdot 3 + 3\cdot 5 & 2\cdot 2 + 1\cdot 4 + 3\cdot 6 \\ 3\cdot 1 + 4\cdot 3 + 1\cdot 5 & 3\cdot 2 + 4\cdot 4 + 1\cdot 6 \end{bmatrix} = \begin{bmatrix} 20 & 26 \\ 20 & 28 \end{bmatrix}$$

解答 3.4.1

$$AB = \begin{bmatrix} 20 & 26 \\ 20 & 28 \end{bmatrix}$$

矩阵乘法难度不高，但需要极为仔细。

问题 3.4.2

已知矩阵的列向量表示：

$$A = \begin{bmatrix} v_1 & v_2 & \cdots & v_n \end{bmatrix}$$

求 A^TA。

字母运算，反而没有数值运算那么容易错。

实际上，矩阵 A 的转置就是这样的行向量矩阵：

$$A^T = \begin{bmatrix} v_1^T \\ v_2^T \\ \vdots \\ v_n^T \end{bmatrix}$$

这样，A^TA 可以写成以下形式：

解答 3.4.2

$$A^T A = \begin{bmatrix} v_1^T v_1 & v_1^T v_2 & \cdots & v_1^T v_n \\ v_2^T v_1 & v_2^T v_2 & \cdots & v_2^T v_n \\ \vdots & \vdots & \ddots & \vdots \\ v_n^T v_1 & v_n^T v_2 & \cdots & v_n^T v_n \end{bmatrix}$$

实际上，对于列向量 v 来说，$v^T v = v \cdot v = \|v\|^2$ 就是内积。

嗯，剩下就没什么东西了，行列式、特征值、线性变换过一遍，线性代数问题也不大。

⊙ ⊙ ⊙

我们用线性代数的语言把我们先前的概念重新叙述一遍。

“线性代数？是矩阵之类的吗？为什么要用矩阵来描述随机变量呢？”

这是因为在现实世界中，我们面对的变量和参数是非常多的，使用矩阵能够更简洁地表示有关概念。我们就先从随机向量开始吧。

“随机向量……Random Vector？”

没错，具体来说，对于随机变量 $X_1, \cdots, X_n$，我们使用一个列向量来表示它们：

$$X = \begin{bmatrix} X_1 \\ X_2 \\ \vdots \\ X_n \end{bmatrix}$$

这里的 X 就是一个随机向量。

随机向量的期望也是一个向量。

$$\mathbb{E}[X] = \begin{bmatrix} \mathbb{E}[X_1] \\ \mathbb{E}[X_2] \\ \vdots \\ \mathbb{E}[X_n] \end{bmatrix}$$

对于随机向量 X 和 Y，我们用协方差矩阵来描述它们之间的协变性。

$$\Sigma = \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])^T]$$

“这里的 T 是什么意思呢?”

这里的 T 表示矩阵转置（Transpose），它将一个 $n \times m$ 矩阵变为一个 $m \times n$ 矩阵，且满足 $(A^T)_{ij} = A_{ji}$。例如：

$$\begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix}^T = \begin{bmatrix} 1 & 4 \\ 2 & 5 \\ 3 & 6 \end{bmatrix}$$

“$X - \mathbb{E}[X]$ 是一个向量吧，它的转置又是什么呢?”

其实，一个 n 维列向量可以看成一个 $n \times 1$ 矩阵，这样它的转置就是一个 $1 \times n$ 矩阵。这样，对于两个随机向量 $X \in \mathbb{R}^n$ 和 $Y \in \mathbb{R}^m$，它们的协方差矩阵 $\Sigma_{XY} = Cov(X, Y) \in \mathbb{R}^{n \times m}$ 具有以下性质：

$$(\Sigma_{XY})_{ij} = Cov(X_i, Y_j)$$

“协方差矩阵的每一个元素，都表示一对随机变量的协方差?”

没错，这是协方差矩阵的重要特点。接下来，我们讨论随机向量自身的协方差 $\mathrm{Cov}(X, X) = \mathrm{Var}(X)$。

问题 3.4.3

假如 X 是 n 维随机向量，$\Sigma = \mathrm{Cov}(X, X)$ 是其协方差矩阵。则 Σ 主对角线上的元素是什么？$\Sigma^T = \Sigma$ 成立吗?

“协方差矩阵表示的是随机变量对之间的协方差，那主对角线就是随机变量和自己的协方差，也就是 X_i 的方差?”

完全正确！$\Sigma_{ii} = \mathrm{Cov}(X_i, X_i) = \mathrm{Var}(X_i)$ 就是随机变量的方差，而由于 $\mathrm{Cov}(X, Y) = \mathrm{Cov}(Y, X)$，我们也能导出 Σ 的对称性。

解答 3.4.3

Σ 主对角线上的元素表示随机变量的方差。$\Sigma^T = \Sigma$ 成立，表明了 Σ 的对称性。

接下来，我们的工作就是将线性回归问题用线性代数的语言重新写一遍，同时拓展到多元情形。

3.5 多元线性回归

在多元线性回归中，我们希望通过多个自变量 x 来预测因变量 y，也就是说：

$$y = w_0 + w_1 x_1 + w_2 x_2 + \cdots + w_n x_n$$

用线性代数的记号，可以写成：

$$y = w^T x$$

这里的 $x = \begin{bmatrix} 1 \\ x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix}$，$w = \begin{bmatrix} w_0 \\ w_1 \\ w_2 \\ \vdots \\ w_n \end{bmatrix}$ 就是将变量写成了向量的形式。

我们仍然希望最小化均方损失：

$$MSE = \frac{1}{m} \sum_{i=1}^{m} (w^T x - y)^2$$

“这里的 m 是什么意思呢?”

这里的 m 表示我们有 m 个样本，也就是 m 组观测数据。为了方便，我们也会把所有的样本都写到一个矩阵当中，也就是这样：

$$X = \begin{bmatrix} x_1 & x_2 & \cdots & x_m \end{bmatrix}$$

这里的 x_i 表示第 i 个样本，是一个 $(n+1)$ 维列向量。

同理，

$$y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_m \end{bmatrix}$$

这样，模型就可以用矩阵形式写出：

$$y = w^T X$$

我们来验证一下：w 是 $(n+1)$ 维列向量，所以 w^T 是 $1\times(n+1)$ 矩阵，而 X 是 $(n+1)\times m$ 矩阵，所以 y 是 $1\times m$ 矩阵，也就是 m 维列向量，这是正确的。

我们仍然使用最小二乘法，也就是最小化均方损失函数：

$$\mathrm{MSE} = \frac{1}{m}\|y - y^*\|^2$$

这里的求解需要用到复杂的代数变形，其解如下：

$$w = (X^T X)^{-1} X^T y$$

这里的 $(X^T X)^{-1} X^T$ 称为矩阵 X 的伪逆，也可以写成 $X^\dagger$，它是方阵的逆的推广。

⊙ ⊙ ⊙

“如果这样的话，做线性回归不会很麻烦吗?”

“可以调用 sklearn”，理纱打开了 IDE，写起了程序。

```
import pandas as pd
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_squared_error
data = pd.read_csv('linear_regression_dataset.csv')
model = LinearRegression()
X, y = data.iloc[:, :-1], data.iloc[:, -1]
```

```
model.fit(X, y)
y_pred = model.predict(X)
mse = mean_squared_error(y, y_pred)
print(f'Mean Squared Error: {mse}')
```

sklearn 提供了大量的机器学习模型，其中就包括了线性回归模型，这样就不用每次都手动计算了。虽然省去了具体计算的麻烦，但如果不理解其中的原理，也没有办法很好地将这些工具利用在现实问题的解决上。

“我觉得我们可以在讲述统计学概念的基础上，利用这些模型解决一个现实问题。”泰朵拉提出了建议。

嗯，统计学和机器学习可以解决很多问题，实际上，发现一个有趣的问题和使用工具解决问题同样关键。如果想要让 *Eulerians* 或者夏令营报告吸引人的话，一个好的问题发现和定义是非常重要的。

第 4 章

假设检验

4.1 p 值与临界值

米尔嘉回来了。

在美国的大学生活是怎样的呢？一定很忙碌吧，我想。

去机场的路上，灼人的阳光和闷热的天气告诉人们，夏天来了。

我曾经认为我和米尔嘉只是有着对数学共同爱好的朋友，并没有交往的倾向，这是零假设 H_0。

我想起那柑橘味的水果香、摩天轮里的相拥、灿烂烟火下那无可替代的笑容、分别时的异样不舍，这是对应 p 值的小概率事件。

假设检验告诉我们，当 $p < \alpha$ 时，我们应当拒绝零假设 H_0 并接受备择假设 H_1，此时犯错误的概率不超过 α。

只不过，在这个问题中犯弃真错误的代价太高，我无法承受，以至于犹豫到了现在。

我还要忍受懦夫一样的自己多久？

“米尔嘉学姐出来了！”

1、1、2、3——泰朵拉做起了斐波那契手势。

我看到了米尔嘉的回应，她张开手掌，做出了 5 的手势，让人一眼就能看到。

我们接过米尔嘉手中的行李，朝着电车的方向走去。米尔嘉的眼神中透着疲惫，但她仍然保持着如柑橘般甜美的笑容，就像第一次见到她，在樱花树下那样。

“Eulerians, reunite!”

⊙ ⊙ ⊙

“最近有学了什么新的数学内容?”米尔嘉问我们。

“学了很多呢！有参数估计，回归分析，虽然不是特别懂，但是学长很厉害呢！教了我们很多东西。”泰朵拉像机关枪一样地说。

米尔嘉看我的眼神似乎有些不同以往，似乎是欣慰，但又有一种说不出的……幽怨?

不管了，还是 *Eulerians* 的事情要紧。

“主要还是为了 *Eulerians* 做准备。现在已经有了统计的基本知识，我们还可以就假设检验的数学原理进行较为深入的讨论，主要是 p 值和临界值两个量之间的关系。”我补充道。

“p 值和临界值，它们有什么联系喵?”

“考验你的时候到了，我们的‘新老师’”。

⊙ ⊙ ⊙

我们考虑正态总体 $\mathcal{N}(\mu, \sigma^2)$，其中 σ^2 为已知量。我们找到了一组样本：$X_1, X_2, \cdots, X_n$。假设我们的样本统计量 $T = \bar{X}$，根据之前的结论，如果零假设 $H_0 : \mu = 0$ 成立，样本统计量 T 也应该服从一个正态分布：$T \sim \mathcal{N}(0, \frac{\sigma^2}{n})$。如果 H_0 成立，我们可以预见 T 不应该偏离 0 太多。现在对于某一组特定样本，我们观察到样本均值为 $\hat{\mu}$。可以肯定，当 $|\hat{\mu}|$ 越大时，$P(T = \hat{\mu}|H_0)$ 越小。

但是，$P(T = \hat{\mu}|H_0)$ 不是 p 值。p 值指的是在 H_0 成立的条件下当前状况或者更极端情况发生的概率，也就是 $p = P(|T| \geqslant |\hat{\mu}|)$。为了简单起见，我们不妨假设观测得到的 $\hat{\mu} > 0$。那么，相应的 p 值可以写成这样一个表达式：

$$p = 2\int_{\hat{\mu}}^{\infty} \phi\left(\frac{x}{\sigma/\sqrt{n}}\right)dx = 2\left(1 - \Phi\left(\frac{\hat{\mu}}{\sigma/\sqrt{n}}\right)\right) = 2\Phi\left(\frac{-\hat{\mu}}{\sigma/\sqrt{n}}\right)$$

如果 p 值足够小，我们就认为原假设不成立从而推翻原假设。那么要多小才算小呢？这就需要在假设检验前指定显著性水平 α，并认为小于 α 的 p 值才算足够小。一般习惯取 $\alpha = 0.05$。

还记得观测统计量 $\hat{\mu}$ 吗？我们说 $\hat{\mu}$ 越大，p 值越小。那么当 $\hat{\mu}$ 足够大的时候我们认为原假设不成立从而推翻原假设。同样的问题又出现了：多大才算大？于是我们引入了临界值 C_α，并规定当 $\hat{\mu} > C_\alpha$ 时我们拒绝原假设。显然，显著性水平 α 和 C_α 会有某种换算关系。

问题 4.1.1

构造此时显著性水平 α 和临界值 C_α 之间的关系。

“我知道了，当 $p = \alpha$ 时是临界情况，此时的 $\hat{\mu}$ 的值就是临界值 C_α！所以只要解一个方程就好了。”泰朵拉算了起来。

$$
\begin{aligned}
2\Phi\left(\frac{-C_\alpha}{\sigma/\sqrt{n}}\right) &= \alpha \\
\frac{-C_\alpha}{\sigma/\sqrt{n}} &= \Phi^{-1}\left(\frac{\alpha}{2}\right) \\
C_\alpha &= -\frac{\sigma}{\sqrt{n}}\Phi^{-1}(\alpha/2)
\end{aligned}
$$

完全正确。利用关系式子 $-\Phi^{-1}(\alpha/2) = \Phi^{-1}(1-\alpha/2)$，我们可以将结果写成这样的形式：

解答 4.1.1

$$C_\alpha = \frac{\sigma}{\sqrt{n}}\Phi^{-1}\left(1-\frac{\alpha}{2}\right)$$

这样的结果还是不太美观。我们可以构造 $Z = \frac{T-0}{\sigma/\sqrt{n}} \sim \mathcal{N}(0,1)$，这样就是对标准正态分布统计量的检验，相应的临界值 $C_\alpha = \Phi^{-1}(1-\alpha/2) = z_{\alpha/2}$。特别的，对于常见的 $\alpha = 0.05$ 的情形，$z_{\alpha/2} = 1.96$。

这就是对于已知方差情况下对均值的假设检验，称为 **Z** 检验。如果零假设 H_0 的形式是 $\mu = \mu_0$，相应的检验统计量可以这样构造：

$$Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}}$$

当 $|Z| > z_{\alpha/2}$ 时，我们拒绝零假设。这样，区间 $(-z_{\alpha/2}, z_{\alpha/2})$ 就是置信区间，置信区间以外的部分就是拒绝域。我们可以通过判断检验统计量是否在拒绝域内来判断是否要拒绝零假设。

⊙ ⊙ ⊙

“一下子讲这么多吗?”米尔嘉不满地说，“虽然好像确实不太难理解，但是你这也太快了吧。‘知识的诅咒’，你也未能幸免啊。”

“把它叫作 Z 检验，是因为引入了名为 Z 的检验统计量吗？那我们之前学过的卡方检验，是不是就是统计量为卡方的检验呢？我还看到过 t 检验，F 检验，是不是说也有名为 t 和 F 的统计量呢？”泰朵拉的求知欲今天异常旺盛。

我说不出话来，课上确实讲过 t 分布和 F 分布，但我清楚地记得我忘了。

“它们都是正态分布的好朋友哦。”米尔嘉这么一提醒，我倒是想起来了。

4.2 正态分布的朋友们

我正想说些什么，被米尔嘉制止了。

“这次的旅程，请先让她们自己探索。”

米尔嘉拿出几张卡片，在上面写起了公式。

$$X_1, X_2, \cdots, X_n \sim \mathcal{N}(0,1) \quad \text{(i.i.d.)}$$

$$Y = \sum_{i=1}^{n} X_i^2 \sim \chi_n^2$$

$$X \sim \mathcal{N}(0,1), Z = \frac{X}{\sqrt{Y/n}} \sim t_n$$

$$Y_1 \sim \chi_{n_1}^2, Y_2 \sim \chi_{n_2}^2, F = \frac{Y_1}{n_1} / \frac{Y_2}{n_2} \sim F(n_1, n_2)$$

“时间不早了，这些就作为回去的思考题吧。”

由于是盛夏，太阳下山得晚，我们在落日的余晖中并排向家的方向走去。

泰朵拉、尤里和理纱走在了前面，有一搭没一搭地聊着天。我和米尔嘉则在后面慢慢跟着。

“正态分布的朋友……好有趣的比喻。”

卡片上的这些公式，令我的记忆如潮水般涌现。这些分布每一个都对应了假设检验中的重要检验方法。

“多给她们一点思考的时间。你学了很多，但是在教别人这一方面，欠缺的还有许多。”米尔嘉靠近我的肩膀。

也行，至少现在不是“不配当老师”了。

“不过我在想，是不是也需要给你多一些的时间？”米尔嘉抓住了我的手腕，“当然我说的不只是锻炼教学能力这一方面。你看这斜阳，多美啊。”

米尔嘉什么时候会这样说话了？

“其实因为地日距离和大气折射，我们看到的也只是太阳在过去的像罢了。难道我们看到的，终究只能是过去吗？”

说到这里，我愈发悲凉了。泰朵拉她们走得快，我仿佛看到了自己离过去的那段美好正在越来越远。

“也给自己一点时间吧。”米尔嘉突然抓住我的手。

脸颊好烫。

“就像这样，紧紧的，再停留一会儿……”米尔嘉一改往日的从容，竟愈发显得迫切。

……

“米尔嘉学姐！太阳要落山了，你们还不回去吗？”她们已经在前面停下来等我们了。

米尔嘉的脸颊红扑扑的，抓着我的手就往前奔去。

好疼！

⊙ ⊙ ⊙

“哥哥，这个长得奇怪的 X 是什么东西喵？”

“这是希腊字母 χ（读作/kaɪ/）。这里的 $Y \sim \chi^2_n$ ”表示 Y 服从自由度为 n 的卡方分布。”

“自由度，就是右下角的那个 n 吗？看起来很复杂的样子，不过 Y 似乎是一系列独立同分布的标准正态分布之和，那我们也可以一样求出它的期望和方差吗？”

$$Y = X_1^2 + X_2^2 + \cdots + X_n^2$$

问题 4.2.1

求自由度为 n 的卡方分布 $Y \sim \chi^2_n$ 的期望和方差。

“如果要求期望的话，可以利用期望的线性性质！”尤里一下就抓住了问题的关键。

$$\begin{aligned}
\mathbb{E}[Y] &= \mathbb{E}[X_1^2 + X_2^2 + \cdots + X_n^2] \\
&= \mathbb{E}[X_1^2] + \mathbb{E}[X_2^2] + \cdots + \mathbb{E}[X_n^2] \\
&= n\mathbb{E}[X_1^2] \\
&= n(\mathrm{Var}(X_1) + (\mathbb{E}[X_1])^2) \\
&= n
\end{aligned}$$

“因为是独立同分布，所以方差也有类似的线性性质。”

$$\begin{aligned}\mathrm{Var}(Y) &= \mathrm{Var}(X_1^2 + X_2^2 + \cdots + X_n^2) \\ &= \mathrm{Var}(X_1^2) + \mathrm{Var}(X_2^2) + \cdots + \mathrm{Var}(X_n^2) \\ &= n\mathrm{Var}(X_1^2)\end{aligned}$$

“只要求出 X_1^2 的方差，就可以求出 Y 的方差了。但是这个看起来好难喵。”

“尤里，我们可以利用方差和期望的关系。”

$$\mathrm{Var}(X_1^2) = \mathbb{E}[X_1^4] - (\mathbb{E}[X_1^2])^2$$

“我们把随机变量幂的期望叫作‘矩’。刚刚我们已经求得了二阶矩 $\mathbb{E}[X_1^2] = 1$，接下来我们只要求出四阶矩 $\mathbb{E}[X_1^4]$ 就可以了。”

$$\begin{aligned}\mathbb{E}[X_1^4] &= \int_{-\infty}^{\infty} x^4 \phi(x) dx \\ &= \int_{-\infty}^{\infty} x^4 \cdot \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right) dx \\ &= \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} x^4 \exp\left(-\frac{x^2}{2}\right) dx\end{aligned}$$

“这个积分还是好复杂喵。”

“尽管如此，但是我们可以利用已知的 $\int_{-\infty}^{\infty} \phi(x) = 1$ 的结果。”

$$\int_{-\infty}^{\infty}\phi(x)dx=\int_{-\infty}^{\infty}\frac{1}{\sqrt{2\pi}}\exp\left(-\frac{x^2}{2}\right)dx=1\Rightarrow\int_{-\infty}^{\infty}\exp\left(-\frac{x^2}{2}\right)dx=\sqrt{2\pi}$$

“注意到 $x\exp(-x^2/2)dx=d(-\exp(-x^2/2))$，我们可以由此换元。”

$$\begin{aligned}\frac{1}{\sqrt{2\pi}}\int_{-\infty}^{\infty}x^4\exp\left(-\frac{x^2}{2}\right)dx&=\frac{1}{\sqrt{2\pi}}\int_{-\infty}^{\infty}x^3d\left(-\exp\left(-\frac{x^2}{2}\right)\right)\\&=\frac{1}{\sqrt{2\pi}}\cdot3\int_{-\infty}^{\infty}x^2\exp\left(-\frac{x^2}{2}\right)dx\\&=\frac{1}{\sqrt{2\pi}}\cdot3\int_{-\infty}^{\infty}xd\left(-\exp\left(-\frac{x^2}{2}\right)\right)\\&=\frac{1}{\sqrt{2\pi}}\cdot3\cdot1\int_{-\infty}^{\infty}\exp\left(-\frac{x^2}{2}\right)dx\\&=\frac{1}{\sqrt{2\pi}}\cdot3\cdot1\cdot\sqrt{2\pi}\\&=3\end{aligned}$$

“从而，我们有 $Var(X_1^2)=3-1=2$，进而有 $Var(Y)=2n$。”

解答 4.2.1

自由度为 n 的卡方分布期望为 n，方差为 $2n$。

“这里用到了好复杂的积分喵。这个方法叫换元法是吗？之前好像也用过，但不太熟练，不能一眼看穿式子的结构。”

“尤里还没系统学过微积分，这个确实比较困难了。但是，只要尤里认真学好数学知识，总有一天也能熟练地运用这些工具解决问题的。”

“后面的 t_n 和 $F(n_1, n_2)$ 就是 t 分布和 F 分布吧，它们也是正态分布的好朋友呢！”

问题 4.2.2

求自由度为 n 的 t 分布 $Z \sim t_n$ 的期望和方差。

“t 分布……看起来像一个标准正态分布除以一个‘标准化’的卡方分布，它们是相互独立的关系，也就是说可以直接将期望写成积的形式。”

$$\mathbb{E}[Z] = \mathbb{E}\left[\frac{X}{\sqrt{Y/n}}\right] = \sqrt{n}\mathbb{E}[X]\mathbb{E}\left[\frac{1}{\sqrt{Y}}\right] = 0$$

“想一想，这里的 $\mathbb{E}[1/\sqrt{Y}]$ 是一定存在的吗？”

“嗯……$1/\sqrt{Y}$ 是卡方分布的平方根的倒数。如果不知道卡方分布的概率密度函数，就难以判断这个期望是否存在。不过，我们可以说‘如果 t 分布的期望存在，那么一定为 0’，对吧？”

“尤里也学会了数学家严谨的表达呢。”

“方差的话，同样也可以利用方差和期望的关系。”

$$\begin{aligned}\mathrm{Var}(Z) &= \mathbb{E}[Z^2] - (\mathbb{E}[Z]^2) \\ &= \mathbb{E}\left[\frac{X^2}{Y/n}\right] \\ &= n\mathbb{E}[X^2]\mathbb{E}\left[\frac{1}{Y}\right] \\ &= n\mathbb{E}\left[\frac{1}{Y}\right]\end{aligned}$$

“还是要用到卡方分布的概率密度函数……怎么这么难！”

“尤里知道自己卡在了哪一步，这是数学学习中非常重要的一点。现在的核心任务在于直接处理卡方分布的概率密度函数，这一点以我们现有的知识还做不到。”

“如果是米尔嘉大人的话，一定没问题的吧。”尤里带着遗憾说。

我之所以没有继续提示，其实真实的原因是我自己也忘了。

也是，当时就是直接记住结论，然后套用到假设检验当中。检验也多半是查表，很少需要这样动手计算微积分。米尔嘉的卡片，其实也是在有意触及我的知识盲区吧。

我离米尔嘉，还差得远呢。

⊙ ⊙ ⊙

“我们来整理一下大家思考的成果。”米尔嘉开始在纸上写了起来。

卡方分布（χ^2_n）：期望为 n，方差为 $2n$；

t 分布（t_n）：期望为 0（若存在），方差待求【需要用到卡方分布的密度函数】；

F 分布（$F(n_1, n_2)$）：期望、方差待求。

“大家已经发现了问题的关键在于卡方分布的概率密度。这里涉及到复杂的多元微积分技巧，所以我直接写出来。”

$$f(x) = \begin{cases} \frac{1}{2^{n/2}\Gamma(n/2)} x^{n/2-1} e^{-x/2} & (x > 0) \\ 0 & (x \leqslant 0) \end{cases}$$

“大家看到这里的 Gamma 函数了吗？这是阶乘的推广，当 n 为正整数时，$\Gamma(n) = (n-1)!$，在讨论黎曼猜想时我们也曾见过这个函数。实际上，Gamma 函数可以写成一个积分。”

$$\Gamma(x) = \int_0^{\infty} t^{x-1} e^{-t} dt$$

“这样，先前的 $\mathbb{E}[1/\sqrt{Y}]$ 就可以用一个积分写出来了。尤里，这一步交给你。”米尔嘉把纸和笔递给尤里。

“有了卡方分布的表达式，代入相应的概率密度，就可以写出来了。”

$$\begin{aligned} \mathbb{E}[1/\sqrt{Y}] &= \int_0^{\infty} x^{-1/2} \cdot \frac{1}{2^{n/2}\Gamma(n/2)} x^{n/2-1} e^{-x/2} dx \\ &= \int_0^{\infty} \frac{x^{n/2-3/2} e^{-x/2}}{2^{n/2}\Gamma(n/2)} dx \\ &= \frac{1}{2^{n/2}\Gamma(n/2)} \int_0^{\infty} x^{n/2-3/2} e^{-x/2} dx \end{aligned}$$

“很好，尤里已经对这个积分提取出了常数，我们可以只关心右边这一部分。”

$$\int_0^\infty x^{n/2-3/2}e^{-x/2}dx = 2^{n/2-1/2}\Gamma(n/2-1/2)$$

“这个结果同样比较复杂，因此我就直接给出了。当 $n = 1$ 时，式子中会出现 $\Gamma(0)$，此时的函数值为复无穷。因此，期望当且仅当 $n > 1$ 时存在，且期望存在时其值为 0。”

“这样的话，方差也能用类似的方法求出吗？”泰朵拉拿过了纸，也写起了积分表达式。

$$\begin{aligned}
\mathrm{Var}(Z) &= n\mathbb{E}\left[\frac{1}{Y}\right] \\
&= n\int_0^\infty \frac{1}{x}\cdot\frac{1}{2^{n/2}\Gamma(n/2)}x^{n/2-1}e^{-x/2}dx \\
&= \frac{n}{2^{n/2}\Gamma(n/2)}\int_0^\infty x^{n/2-2}e^{-x/2}dx
\end{aligned}$$

“完全正确！我们只需要代入相应积分的计算结果就可以求出方差了。在这一步简化中，需要用到 $x\Gamma(x) = \Gamma(x+1)$。”

$$\frac{n}{2^{n/2}\Gamma(n/2)}\int_0^\infty x^{n/2-2}e^{-x/2}dx = \frac{n}{2^{n/2}\Gamma(n/2)}2^{n/2-1}\Gamma(n/2-1) = \frac{n}{n-2}$$

“类似的，这个表达式只在 $n > 2$ 时有意义。到目前为止，我们已经成功得到了 t 分布的期望和方差。”

解答 4.2.2

自由度为 n 的 t 分布的期望为 0（当 $n > 1$ 时存在），方差为 $\frac{n}{n-2}$（当 $n > 2$ 时存在）。

“F 分布的求解同样要用到复杂的微积分。这里我就直接给出了。”

$$\mathbb{E}[F] = \frac{n_2}{n_2 - 2}, Var(F) = \frac{2n_2^2(n_1 + n_2 - 2)}{n_1(n_2 - 2)^2(n_2 - 4)}$$

⊙　⊙　⊙

“真是一场苦战喵。”尤里累得趴在了桌子上。

“这么复杂的微积分，我们怎么算得出来?”我本来想说“她们”，但是一想到自己也算不出来，于是改口。

“我可没保证利用你们现有的知识一定能算出来。就像村木老师的卡片一样，关键的是要去‘想’。还记得分拆数问题吗？到最后也没导出通项公式，但是这个思考的过程才是更为重要的。”

说到这里，米尔嘉顿了一下。

“是不是感觉自己被捉弄了?”她突然笑着对我说，弄得我一时支支吾吾说不出话来。

“正态分布的这么多好朋友，它们都有什么用呢?”泰朵拉问。

“轮到你了。”米尔嘉将纸和笔递给了我。

4.3 卡方拟合优度检验

我们对“骰子是否公平”进行假设检验。假设我们一共扔 n 次骰子，骰子实际掷出点数 i 的次数为 O_i，期望掷出点数 i 的次数为 E_i。考虑统计量：

$$X^2 = \sum_{i=1}^{6} \frac{(O_i - E_i)^2}{E_i}$$

当骰子公平时，这个统计量不应该太大。那么，多大算太大呢？这就需要我们知道 X^2 服从何种分布。利用 $E_i = n/6$ 和 $\sum_{i=1}^{n} O_i = 1$，我们可以将 X^2 的表达式写成这样：

$$X^2 = \sum_{i=1}^{6} Y_i^2, Y_i = \frac{O_i - n/6}{\sqrt{n/6}}$$

我们引入的 Y_i 称为标准化残差。实际上，随机向量 $(Y_1, \cdots, Y_6)$ 服从一个多项分布。

“多项分布？是二项分布的推广吗？”

没错。由于 O_i 满足 $\mathbb{E}[O_i] = n/6$ 且 $\sum_{i=1}^{6} O_i = 1$，此时的 $(O_1, \cdots, O_6)$ 有多项分布 $\mathrm{Multi}(n; 1/6, \cdots, 1/6)$。对于 $(Y_1, \cdots, Y_n)$，由多元分布的中心极限定理，当 $n \to \infty$ 时，其应当服从多元正态分布 $\mathcal{N}(0, \Sigma)$，且 $\Sigma_{ij} = \delta_{ij} - (\frac{1}{6})^2$。利用一些线性代数，可以得出 $X^2 = Y^T Y$，并得出当 n 很大时，X^2 近似服从自由度为 5 的卡方分布。

“自由度是 5，比 6 少一点呢。”

这是卡方拟合优度检验的重要结论：卡方分布的自由度比类别数少 1。当类别数为 n 时，皮尔逊卡方统计量 $X^2 \sim \chi^2_{k-1}$。然后，我们就可以通过查卡方分布表，将皮尔逊卡方统计量和相应的临界值

C_α 作比较，进而判断是否拒绝零假设了。

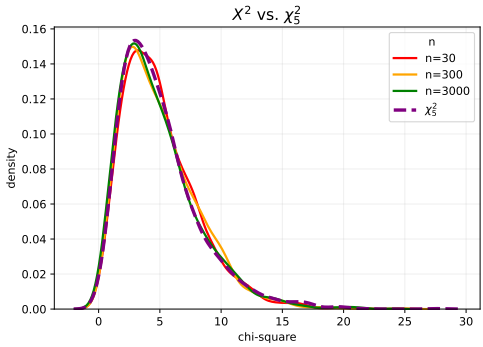
⊙ ⊙ ⊙

“从理论上证明是卡方分布，还是比较困难的吧。不如程序验证一下如何?”米尔嘉看向了许久没说话的理纱。

“模拟掷骰子，计算皮尔逊卡方统计量，画出图像。”理纱迅速开始编写起代码。

```
import seaborn as sns
import numpy as np
import matplotlib.pyplot as plt
np.random.seed(42)
run_time = 2000
pearsons = {}
ns = [30,300,3000]
colors = {10: 'gray', 30: 'red', 300: 'orange', 3000: 'green'}
plt.figure(figsize=(15, 10))
plt.subplot(2, 2, 1)
for n in ns:
    if n not in pearsons:
        expected = n / 6
        pearsons[n] = []
        for _ in range(run_time):
            points = np.random.randint(1, 7, n)
            observed = np.bincount(points, minlength=7)[1:]
            pearson = np.sum((observed-expected)**2/expected)
```

```
                pearsons[n].append(pearson)
        sns.kdeplot(data=pearsons[n], label=f'n={n}',
                    linewidth=2, color=colors[n])
control = np.random.chisquare(5, run_time)
sns.kdeplot(data=control, label='$\chi_5^2$',
            linewidth=3, linestyle='--', color='purple')
plt.title('$X^2$ vs. $\chi_5^2$', fontsize=14)
plt.xlabel('chi-square')
plt.ylabel('density')
plt.legend(title='n')
plt.grid(True, alpha=0.2)
plt.show()
```



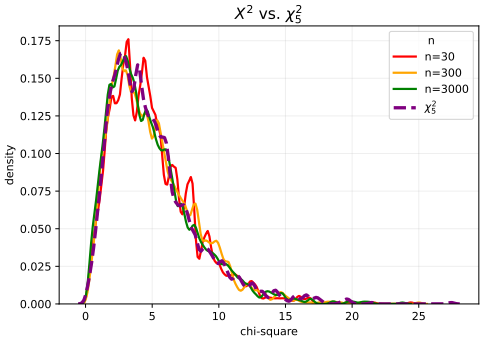
“投掷次数越多，皮尔逊卡方统计量越接近真实的卡方分布。”

“为什么图中的卡方值会出现小于 0 的情况?”泰朵拉的观察很敏锐。

“程序里用了核密度估计，相当于用了很多小的正态分布来拟

合数据，因此即使卡方值全为正，图中也可能出现一部分负值。”理纱立刻开始修改程序。

```
sns.kdeplot(...,bw_adjust=0.3)
```



“通过减少平滑，可以降低尾部延伸至小于 0 的趋势。”

“如果统计量 X^2 过大，说明零假设大概率不成立，但是如果 X^2 过小，也是一个小概率事件，但是是一个‘好’的小概率事件?”

“当然。因为统计量 X^2 是有实际意义的，我们不是真正要判断 X^2 是否服从卡方，而是测试原假设能否很好描述实际情况。因此，卡方拟合优度检验是一种‘单侧检验’，它的拒绝域是只有一边的形式。”

$$\chi^2_n \geqslant k$$

“但是如果卡方值太小，也会有数据造假的嫌疑。”我补充说。

“拟合优度检验能够帮助判断实际数据是否很好地服从某一个分布律。我们不妨再来看一个例子。”

问题 4.3.1

考虑自然常数 $e = 2.718281828\cdots$ 的小数位，零假设 H_0：各个数字出现的频率是均匀的。利用卡方拟合优度检验进行验证。

“首先要获得数字出现的频数。”理纱照例做得很快。

e 的前 1000 个小数位中数字出现的实际频数和期望频数

k	0	1	2	3	4	5	6	7	8	9
O_k	100	96	97	109	100	85	99	99	103	112
E_k	100	100	100	100	100	100	100	100	100	100

“计算得到卡方统计量 $X^2 \approx 4.86$。采用自由度为 9，$\alpha = 0.05$ 的拟合优度检验，临界值 $C_\alpha = 16.919$。由于 $X^2 < C_\alpha$，因此保留原假设。”

问题 4.3.1

因为 $X^2 < C_\alpha$，因此保留原假设，认为各个数字出现的频率是均匀的。

“这个我好像听说过，叫正规数，是吧?”我转向米尔嘉。

“是的，像这样数字分布表现出随机性，且每个数字出现机会均等的数称为正规数。然而，现在并没有严格证明像 e、π 这样的无理数是正规数，现在被严格证明是正规数的那些数都是人造的。”

“看来 *Eulerians* 又可以增加很多新内容了呢。”

◎ ◎ ◎

“我们可以把经典统计学和机器学习结合起来，作为一个汇报展示的内容更合适。”在决定后续内容的讨论会上，我首先提出了意见。

“学校旁边的那家便利店，我们可以尝试预测各类商品销售额和外部因素的关系。”理纱罕见地主动发言，“不过首先，我们要能够获取数据。”

“我跟那家店的老板比较熟，或许我可以去和老板沟通一下。”泰朵拉边说边在笔记本上记着什么。

“我也想一起去!”尤里抱着泰朵拉说。

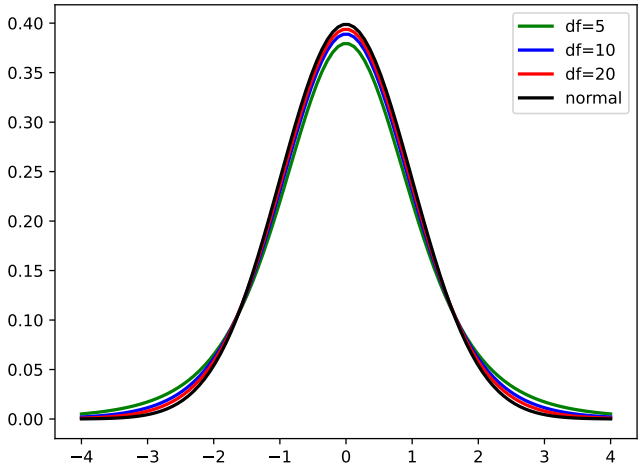
“数学推导和统计建模，后面的任务还挺多的。米尔嘉，理纱，之后会需要你们的帮助。”

Eulerians 的大家开始行动起来。

4.4　t 分布与 t 检验

双仓图书馆，我，米尔嘉，理纱。

“t 分布和正态分布看起来好像。”理纱指了指屏幕。



“你画出了不同自由度下的 t 分布和正态分布的对比，有发现什么规律吗?”米尔嘉问。

“t 分布的尾部比正态分布更厚，自由度越大，越接近正态分布。”

“没错。当自由度趋近于无穷大的时候，t 分布就是正态分布，这就是 t 分布的渐近性质。严格的证明需要用到 Gamma 函数的 Stirling 近似，不过我们已经能从图上看出这样的规律来了。既然 t 分布和正态分布那么像，那么它们应该有相似的用处才对，你说是吧?”米尔嘉看向我。

“之前的 Z 检验用的是正态分布，适用于已知总体方差或者样本足够大的时候。当未知总体方差且样本量较小的时候，用 t 检验更合适。把 Z 统计量的总体方差 σ 换成样本方差 s，就得到了计算 t 检验统计量的公式，相应的自由度为 $n-1$。之所以自由度是 $n-1$，是因为样本方差 s 的计算过程中用到了样本平均数 $\bar{X}$，导致有一个变量的自由度损失了。”

$$t = \frac{\bar{X} - \mu_0}{s/\sqrt{n}} \sim t_{n-1}$$

“我还看到过 t 检验用来比较两组数据均值差异是否显著的应用。”理纱打开一个文档，“分子是两组平均数的差异，差异越大越有可能说明其显著。但是分母是什么？我还不太明白。”

$$t = \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}$$

“你看上面的 $s/\sqrt{n}$，有没有想起些什么？”

“标准误……两组标准误的平方和的平方根？”

“可以这么说。我们做成对 t 检验的时候实际上是希望量化‘两组样本平均值的差异相对于随机波动是否足够大’，而标准误正是随机波动的定量衡量。因此我们在这里就使用这一指标作为分母。另外，此时 t 分布的自由度会稍微复杂一点。”

$$df = \frac{\left(\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}\right)^2}{\frac{(s_1^2/n_1)^2}{n_1-1} + \frac{(s_2^2/n_2)^2}{n_2-1}}$$

“当然，在两组的总体方差一致时，我们可以构造出‘齐性’的 t 统计量，从而让自由度变为更简单的形式。”

$$t = \frac{\bar{X}_1 - \bar{X}_2}{s_p\sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim t_{n_1+n_2-2}$$

$$s_p = \frac{\sqrt{(n_1-1)s_1^2 + (n_2-1)s_2^2}}{n_1 + n_2 - 2}$$

“t 检验为我们提供了在小样本情况下针对均值差异进行显著性检验的工具。想一想：它在我们的研究问题里可能会有哪些运用？”

“检验均值差异的显著性……比如雨天伞的销量显著高于晴天？”

“没错。在我们的便利店场景中，样本数并没有那么多，因此使用 t 检验更为合适。”

◎ ◎ ◎

“我们把数据要到了！”泰朵拉和尤里朝向我们过来。

“干得不错，接下来就要进行数据清洗和特征工程了。”我说。

“数据还要清洗？难道数据不干净吗？”尤里问道。

第 5 章

数据科学与机器学习

5.1 数据预处理与探索性分析

七月流火，九月授衣。

时间远比我想象中过得快，转眼之间，假期已经所剩无几。

过去一个多月的这段时光仿佛如梦境一般，仿佛又一次回到高中，又一次与熟悉的伙伴一同讨论数学，这一切，真的是真实的吗？

我翻了翻高中时的数学笔记，那些往日困扰无数个日夜的难题，竟变得如此简单、清晰。这是否就是一种成长呢？这样说起来，成长的似乎也不只是我自己。

泰朵拉还是那个爱思考的人，理纱还是那个爱编程的人，尤里还是那个爱缠着问问题的人，米尔嘉……还是那个我可望而不可即的人。但是在她们的身上，也正在进行着缓慢逐步的变化过程。

大家因为共同的热爱走到一起，又在以自己的节奏努力成长着。

这样的日子，还能持续多久呢？

◎ ◎ ◎

“数据还要清洗？难道数据不干净吗？”

“这是从财务系统导出的脱敏后的原始数据，我们需要将它转换成程序便于处理的格式，还要处理其中的缺失和异常值。”理纱边说边打开了表格，“来看看里面有什么”。

“有好多列信息，有交易时间、商品列表、支付金额，还有好多好多列。”

“所以我们要把它们做一下整理，比如时间是精确到秒的，而我们只需要大致的时间段就可以了。”

过了五分钟，理纱打开了一个处理之后的新表格。

“用时段取代具体的时间点，可以让数据变得更加简单一些。”

“字段，就是表格里的一列吗?”

“暂时可以这么理解。它是数据库里的概念，在这里对应的就是某一种信息。”

“还是有很多冗余信息，能不能变得更加简单呢? 比如，我们不需要知道商品的品牌等过于详细的信息，只需要知道商品的类别就可以了。”泰朵拉提出了意见，“还有一些表格里没有的因素，比如天气，也可能影响商品销售的情况，是不是可以添加进去?”

“也就是标准化和添加新的特征。”理纱说。

“也就是说，现在需要把商品明细换成商品类别，同时查到每一天的天气数据加入进去。”泰朵拉总结道。

“我可以做这个!”尤里特别积极。

“交给你了。”

那是理纱为数不多的郑重。

⊙　⊙　⊙

“终于找全了，可累坏了喵。”

理纱接过了数据，又开始编写起了程序。

“可以按照时段进行归类，统计出时段的总客流数，生成出新的特征。”

“特征？是像人的高矮胖瘦那样的特征吗？”

“特征是对模型预测最有帮助的变量，有的时候需要从数据中运用各种方式创造出新的变量，这就是特征生成。”我解释说。

“如果是这样，是不是还需要考虑更多的特征，比如促销活动、校园活动之类的？”泰朵拉对着数据陷入深思。

“有道理。”理纱按下了运行键，“只要是对结果可能有关键影响的因素，我们都要将其加入特征。”

理纱打开了一个文档。

特征选取清单

- 日期与时段（原始数据中提取）
- 是否工作日（利用原始数据构造）
- 天气（外部数据）
- 校园活动（外部数据）
- 时段客流量（利用原始数据构造）
- 消费品类（利用原始数据构造）
- 消费金额（原始数据中提取）

“我有一个问题，”泰朵拉说，“如果要把像‘校园活动’这样的特征编写到数据表当中，是不是需要将它转换成数字的形式？因为它不仅仅是一个‘是或否’的用 0 或者 1 表示的量，那又要如何处理呢？”

“特征编码，方式有很多，这里用哑变量应该更好。”理纱往程序里添加代码。

“多种校园活动的话，能不能直接用 1234 这样进行编码呢……不对，如果这样的话就人为引入了顺序，可能会让模型造成误判。”尤里说，“哑变量就是为了避免这种问题吗?”

“没错，这就是哑变量的作用。”我解释道，“具体而言，就是对于每一种校园活动都建立一个‘是否 XX’的二元指示变量，比如‘是否开学典礼’‘是否运动会’，这样的指示变量就称为哑变量。特别的，对于无活动的情况，我们只要令每一个哑变量都为 0 就可以了。”

“原来如此，数据科学好复杂喵!”

⊙　⊙　⊙

“接下来我们需要进行所谓的‘探索性分析’。”米尔嘉边说边在纸上写，“这只是所谓‘数据科学家’给用传统统计方法分析数据起的时髦名字，其实就是应用我们先前学习的大量统计学知识去探寻数据的潜在规律。有的时候，它往往比模型本身更重要。理纱，你知道 3σ 原则吗?”

理纱摇了摇头。

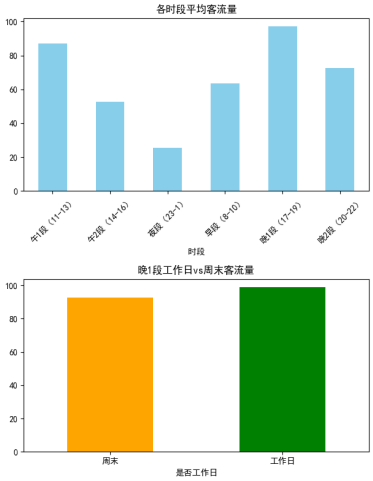
“所谓 3σ 原则，就是说正态总体的绝大部分都落在 $\mu \pm 3\sigma$ 的范围内，因此这个范围内之外的数值称为异常值。理纱，能否检查一下客流量和消费金额是否存在异常值?”

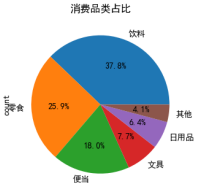
“客流量和消费金额都有异常值。”理纱一如既往地快，“但是，如果这些异常值在逻辑上是合理的，也不能盲目地删除它们。”

“如果是消费金额过多的情况，能不能做适当拆分? 考虑到可能是合买带来的异常值。”泰朵拉说。

“这样真的可以喵？感觉很不精确的样子……”

“在实际问题中，我们往往做不到绝对的精确，”我对尤里解释道，“所以这时就需要我们利用已知的先验知识进行大致的分析，这种基于经验的处理方式在数据科学中是很重要的。”





“探索性分析图表，属于描述统计的内容。”理纱说。

“从描述统计到推断统计，是人们对于数据认识和处理的方法论的一次飞跃。泰朵拉，尤里，从这张图表上你们看到了什么？”米尔嘉问。

“晚一段的工作日客流比周末高一点。”尤里说。

“时段客流存在明显的潮汐效应。”泰朵拉补充说，“刚刚米尔嘉学姐提到‘推断统计’，是不是说从图表上观察到的结论还不够有说服力，需要用统计推断的方式来验证？”

“没错，这就需要借助推断统计中的假设检验。还记得检验均值差异是否显著应该怎么做吗？”米尔嘉看向泰朵拉。

“t 检验对吧。通过比较组间变异性相对于组内变异性是否足够大，从而判断均值的差值更有可能是随机波动造成的还是系统性差距。”

“p 值小于 0.05，可以认为存在显著差异。”理纱边运行程序边说。

“今天的探索性分析提供了很多有用的洞察，之后我们就要基于这些结果，建立相应的回归模型了。”不知道为什么，我好像在抢米尔嘉的话似的。

5.2　回归模型的选择与评价

“今天补充得不错嘛，挺像大哥哥。”

我被米尔嘉说得有些脸红。好久没有像这样在海边单独见面了。

“米尔嘉……我感觉最近学的那些数学，跟之前做的，有很大的不同。”

“为什么会有这样的想法呢?”

“之前的那些问题，像是伽罗瓦理论、庞加莱猜想这些，应该是属于‘纯数学’之类的吧。它们研究的都是群、流形这样高度抽象的数学对象。但是现在，我感觉自己扎到了另一个直接面向实际世界的‘应用数学’的世界里，不像数学了，更像是……工程?”

米尔嘉突然停下了脚步。

“纯数学和应用数学都是数学的重要部分，虽然它们存在巨大的差异，但都确实地为人类社会的发展做出了巨大的贡献。你是在否认自己所投身的事业的价值吗？还是说，你在担心的是别的什么东西?”

我们曾经约定过的，要一起讨论数学。

虽然名字仍然叫作“数学”，但某种程度上来说，已经是不一样的东西了。

在美国做纯数学研究的日子一定很累吧。百忙之中回到这里，看到我从那个和她一起探究形式之纯粹与抽象之螺旋的少年，成为现在这个在繁杂世界里不断接受“不完美”的迷途之子，会对我失望吗？

恍惚间，我又回到高一，看到那棵樱花树下的召唤。

“数列智力题没有正确答案。”那是我们讨论之后的结论。但是，我却在当下有了不同的看法。

$1, 3, 5, 7, 9, \cdots$，这是纯粹与美。

$0.95, 2.99, 5.01, 6.85, 8.96, \cdots$，这也许是现实世界。

$0.95, 2.99, 5.01, 6.85, 8.96, 114.5$，这是过拟合。

我仿佛又看到了那棵樱花树未曾注意的细节：没有两片花瓣是相同的，也没有哪片花瓣和博物志上的一模一样。那么，我们又是如何辨别它们的，又如何保证我们的辨别不会出错呢？

正当我胡思乱想的时候，那熟悉的柑橘味芳香将我从幻象中拉回。

（好近！）

“那些东西，没那么完美，但也是数学。”

海风将米尔嘉的头发吹在我的脸上，痒痒的。

“纯数学和应用数学，只是我们的选择，没有高低之分。按照约定，我们还会继续一起讨论数学。”

米尔嘉松开了怀抱。

“你对应用数学的了解比我多，接下来需要你给泰朵拉她们讲

一下这些，拜托了。”

⊙　⊙　⊙

双仓图书馆。米尔嘉她们在看着我。

我给米尔嘉讲数学？真的假的？

“回归模型的好坏通常用误差的大小来衡量。我们之前已经提过‘最小二乘法’，其实是在最小化均方误差。

$$MSE = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2$$

“另一种误差的表示是平均绝对误差，英文叫 Mean Absolute Error。

$$MAE = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i|$$

“可以看出，$y_i - \hat{y}_i$ 是一个重要的量，它描述了真实值和预测值的差异，我们把它叫作残差。而 $y_i - \bar{y}$ 跟我们的模型无关，我们把它称为偏差。这样，我们就可以引入决定系数。

$$R^2 = 1 - \frac{\sum(y_i - \hat{y}_i)^2}{\sum(y_i - \bar{y})^2}$$

“决定系数 R^2 越接近于 1，说明模型的残差平方和相对于样本自身的偏差平方和越小，模型的预测效果越好。R^2 还有一种解释，就是‘模型解释了样本多少比例的变异’”。

“学长，我有疑问。”泰朵拉举起手，“如果 R^2 很接近 0，说明模型没怎么解释样本的变异吧？但是我发现 R^2 也可能比 0 小，是不是说残差比偏差还大，模型完全失效了？”

“确实是这样。当 $R^2 = 0$ 时，说明模型和‘一律把均值作为预测值’的效果相当，而 $R^2 < 0$ 尽管实际中很少见，但如果出现了，也说明模型比‘一律把均值作为预测值’还要糟糕，模型完全失效了。还有一点要注意，如果数据集不同，不适合用 R^2 比较不同的模型，因为数据分布不同会导致偏差不同。

“决定系数 R^2 和相关系数 ρ 有点像喵，是一回事情吗?”

“不是一回事，虽然它们看起来有相似的形式，而且有的书里把 ρ 写成 r，和 R^2 更像了。但是，R^2 是模型好坏的评估指标，而 ρ 是数据本身线性程度的评估指标，ρ 越接近于 ± 1，说明数据本身越适合使用线性回归来拟合；R^2 越接近于 1，说明模型在给定的数据集上的效果越好，但这个模型本身不一定是线性回归，也有可能是对数回归、多项式回归等。

“还有一点要注意，我们的模型是要面对真实世界大量未见过的数据的，所以我们更关心模型的‘泛化误差’，也就是在没有见过的数据上的误差。常用的做法是划分训练集和测试集，并用在测试集上的误差作为泛化误差的估计。这里涉及到一对重要的概念——欠拟合和过拟合。”

⊙ ⊙ ⊙

这里涉及到一对重要的概念——欠拟合和过拟合。

“过拟合，是说拟合得太好吧，这也是坏事喵?”

过拟合是训练误差小，泛化误差大；而欠拟合则是训练误差已经很大。在实际的模型训练中，更为需要注意的是过拟合。

问题 5.2.1

对于训练数据 $(x_1, y_1), \cdots, (x_n, y_n)$，考虑以下几种训练模型的方式：

(1) 对于任何输入 x，直接使用 $\bar{y} = \frac{1}{n}\sum_{i=1}^{n} y_i$ 作为模型输出；

(2) 不考虑数据本身的线性程度，直接使用线性回归；

(3) 利用多项式插值使得模型能够“穿过”所有训练数据，训练误差为 0。

这些方式存在什么问题？

“如果是用第一种，那就是 $R^2 = 0$ 的情况，模型根本没有什么预测能力；第二种的话，数据非线性的情况下强行用线性模型，肯定也没什么预测能力；第三种……训练误差为 0，但这完全就是硬凑嘛！泛化误差要飞到天上去了喵。”

解答 5.2.1

(1)(2) 会导致欠拟合，(3) 会导致过拟合。

欠拟合是由于模型根本没有从训练数据中学到真实规律，也就是存在极高的偏差；而过拟合则是由于模型方差过大，对于训练数据的微小波动极其敏感，于是模型学到的规律在未见过的数据上失灵了。

“偏差和方差……是 Bias-Variance Tradeoff！”

我们假设自变量是 X，因变量是 Y，两者之间存在真实关系 $Y =$

$f(X)+\epsilon$。现在我们有一组训练样本 $D=\{(x_1,y_1),\cdots,(x_n,y_n)\}$，并基于此训练了一个模型 $\hat{y}=\hat{f}(x;D)=\hat{f}(x)$。对于随机的样本 (x,y)，我们可以写出均方误差：

$$MSE=\mathbb{E}_{D,\epsilon}[(f(x)+\epsilon-\hat{f}(x))^2|x]$$

注意到 $\mathbb{E}[\epsilon]=0$，且 ϵ 与 D 独立，因此以上的均方误差可以写成：

$$MSE=\mathbb{E}_D[(f(x)-\hat{f}(x))^2]+\mathbb{E}[\epsilon^2]=\mathbb{E}_D[(f(x)-\hat{f}(x))^2]+\sigma^2$$

我们用 $\bar{f}(x)=\mathbb{E}_D[\hat{f}(x)]$ 表示模型对于训练集数据的期望预测，则根据 Bias-Variance Tradeoff，均方误差可以写成这样的形式：

$$MSE=(f(x)-\bar{f}(x))^2+\mathbb{E}_D[(\hat{f}(x)-\bar{f}(x))^2]+\sigma^2$$

于是我们知道，泛化误差既和模型的偏差 $f(x)-\bar{f}(x)$ 有关，也和模型的方差 $\mathbb{E}_D[(\hat{f}(x)-\bar{f}(x))^2]$ 有关。欠拟合是偏差过大，过拟合则是方差过大。

“有点明白了……偏差过大是说模型预测的平均结果本身就和真实的规律 $f(x)$ 差得很多，而方差过大就是模型对 D 的变化太敏感……所以要让误差小，偏差和方差都不能太大喵！”

“泛化误差中包含噪声项 σ^2，”泰朵拉若有所思，“那是说任何模型都不可能消除这部分误差吗？”

是的，这称为贝叶斯误差。任何模型的泛化误差都无法低于它，

因为这是由问题本身的噪声决定的——理纱，你有什么想说的？

⊙　⊙　⊙

“理纱，你有什么想说的？”

“我试了一些模型，线性回归效果不太好，随机森林还可以。”

“是集成学习吗？”米尔嘉开口，“之前听说过，果然效果不错。”

“确实，像这里解释变量比较复杂的情况，线性模型效果不太好。要不再试试别的？Boosting 之类的。”我说。

“怎么又开始说一些我听不懂的话了喵！”

5.3　模型训练与调优

我先简要解释一下理纱刚刚的工作。她训练了一个基于若干解释变量（日期与时段、天气等）预测响应变量（客流量）的回归模型。

“模型？就是线性回归，还有刚刚说的随机森林之类的喵？”

差不多，线性回归、随机森林等都是训练模型所用的算法，但是从算法到模型，我们还需要给模型数据，并且让程序在计算机上运行之后才行。也就是说，模型是算法、数据和算力的结合。

“要给算法以数据……就是说，本来模型不知道自己的参数应该是什么，但是从训练数据里，模型可以用梯度下降之类的办法不断调整自己的参数，最后就变成了可以准确预测客流量的程序了喵？”

完全正确！模型会通过数据自己调整内部的参数，从而学会数据的规律。这就是所谓的“机器学习”。还记得我们之前说过的 learning rate 吗？它不是模型学到的参数，而是人为指定，用来控制模型学习过程的参数。这样的参数称为“超参数”，通过调节超参数来让模

型效果更好的过程就是超参数调优。

“运行网格搜索，找到了更好的一组超参数。”

理纱刚刚说的网格搜索就是超参数调优的一种重要方法，其本质思想是枚举可能的超参数的组合，并从中找到效果最好的一个。接下来，只要在测试集上进行测试就能够估计模型的泛化误差了。

“测试集决定系数 $R^2 = 0.84$，集成学习效果不错。之前线性回归的调优过程，我也想放到最后的展示里面。”

理纱这一点提得很好，和纯数学的纯粹相比，应用数学需要不断分析、试错，最终才能得到一个经验上可行的结果。在机器学习领域有个概念叫作 SOTA，全称是 state-of-the-art，它表示在某一特定任务上表现最好的模型。由于我们面对的数据集非常特殊，我们可以认为理纱的模型在当下就是一个 SOTA。

“state-of-the-art……原来我们也能做到喵?”

对于那些非常普遍的问题，已经有很多人做过了，此时追求 SOTA 就会非常困难。然而，现在是我们自己给自己定义问题，所以只要我们尽力了，就能够得到当下的 SOTA。当然，随着越来越多的人研究同样的问题，或者我们的水平更为进步，之前的 SOTA 也会不断被打破，模型的效果也会越来越好。

◎ ◎ ◎

汇报会上，在理纱的强烈意愿下，我们一致决定让她主讲。

这个转变非常令人惊喜，一向内向的理纱愿意主动向观众讲述这些成果，连米尔嘉都感到始料未及。

“我们首先对数据进行了探索性分析，以上是我们的探索性分析图表……通过假设检验，我们认为这种趋势并非由随机波动造成，而是系统性的。

“线性回归的效果不甚理想，但我们通过 L1 正则化，也从中选取了一部分重要的特征……最终，集成学习模型在测试集上取得了良好的预测效果。我们的模型还给出了未来两周的客流预测，并结合探索性分析的结论为便利店运营提出了相应建议。

“以上就是我们团队的成果，请大家批评指正，谢谢。”

台下掌声雷动。理纱回来后，她又恢复了往常沉默寡言的样子，仿佛刚刚已经消耗了她所有的社交能量。

泰朵拉和尤里一边表达对理纱的崇拜和赞美，一边不断地帮她拿来各种茶歇，竟一时弄得理纱有些害羞。

“比起复述论文或者证明过程，这样‘自己动手’的体验，在那次随机算法之后，还没有再来过呢。”米尔嘉说。

“应用数学就是没那么多抽象概念，一直在和数据和模型打交道，关键是要把数学知识用在解决实际问题上。”我说。

我们听完了其他的报告，随后一同前往晚宴。

5.4　机器学习的基本任务

“大胜利喵！干杯——”

与尤里的热情形成了强烈的反差，理纱躲在米尔嘉旁边，一动不动。

“真的非常感谢理纱的工作。从想法到模型实现，理纱真的做得很棒呢。”

理纱听了我的话之后，脸颊微红，倒是显得不那么拘谨了。

“这些内容也可以放到 *Eulerians* 当中吗?我设计好版面样式了。”泰朵拉拿了一块披萨。

“刚刚看到有个组展示的幻灯片好像是用 Liii STEM 编写的，我也想在编写 *Eulerians* 的时候试试这个软件。”提到了技术，理纱又变得大方起来。

“那个组，他们好像也是做的机器学习，但是是个分类任务。”米尔嘉想起来了当时的细节，“它们的准确率还挺高的。”

“机器学习做分类……”泰朵拉又陷入沉思，“就是预测离散量吗？我们的回归预测的是连续量。”

“没错，比如给定一张图片，模型需要分辨是猫还是狗，又或者是给定一张手写数字的图片，模型识别它是几。”我解释道，“理纱应该知道，做过 MNIST 吗？那个手写数字数据集。”

理纱点了点头，也加入了讨论：“回归和分类里面，我们都知道训练数据的真实响应变量，称为‘标签’。所以我们就把回归和分类这种基于有标签数据的学习统称为有监督学习。”

“另一种学习是无监督学习吗?”泰朵拉像是明白了什么似的，“比如给定便利店顾客的消费数据，让模型自己学会把顾客归类为不同的类型，比如‘经济型’‘轻奢型’，但是训练数据里面本身没有标注这些类型，这就是无监督学习吗?”

“这个我听我导师聊过，叫聚类。”米尔嘉说，“让模型自己把数据归成各种各样的类别。还有一种无监督学习任务叫数据降维，把高维特征映射到低维特征空间中，让模型更好处理。”

“有监督学习，还有无监督学习……机器学习真的好复杂喵!”

“还有强化学习，让模型自己和环境交互。”理纱说，“还有半监督学习，自监督学习……任重道远啊。”

“怎么样，大胜利之后还有大仗啊。”我揶揄道。

“哥哥太坏了喵!”

“说起来，刚刚的那组讲分类任务的时候，好像用到了很多评价指标，像准确率、精确率、召回率之类的，它们有什么区别吗?”泰朵拉呷了一口饮料。

“这个就说来话长了。他们应该还提了 F-1 Score，AUROC 之类的吧？下次我们再一起讨论它们吧。”

“为 *Eulerians* 的胜利，干杯!”

⊙　⊙　⊙

“这么晚找我出来，有什么事吗?”

我星夜来到了天台。

“这半年下来，我们的改变都挺大的，我想听听你的看法。”米尔嘉故作轻松，仿佛这是一次闲谈。

“我的看法？这就是成长的一部分吧。我们对数学的热爱都没变，但大家都在变得更好啊。我现在更加会讲数学了，泰朵拉和尤里更加会提问了，理纱更加会表达了……大家还是像以前一样，一起讨论数学，真希望这样美好的日子能持续下去……米尔嘉，你有什么疑问吗?”

“我也感受到了，你真的很擅长启发她们。我在国外，没法时时关照到这边的情况，之后还是要你来领导讨论，因为我过一个星期也要走了。”

我知道会有这样一天的，也知道这并不是永别，但为什么，还是有一些难过呢?

“还有，谢谢你，教会了一些我不知道的数学知识。我相信只要你想，你一定能成为很好的老师。”

她突然牵住我的手，带领我走向天台的高处。

“当我们看星星时，我们实际上在看过去；当我们学习数学的时

候，我们其实也在学习过去。你应该知道，这些知识都不算新的，至少称不上是真正意义上的‘前沿数学’。但是，正是这些不算新的光耀，照亮了我们的生活。”

数学穿越时空。

“我做的纯数学，离真正‘照亮人类’可能需要数十年甚至数百年的时间。而你的应用数学，能够在更短的时间内为人类文明探索增添星火之光，这是你的荣幸，我希望也是我的荣幸。”

最后那半句话有些让我摸不着头脑。

“一辈子……一起讨论数学……可以吗?”

第 6 章

向夜晚奔去

6.1 未来与选择

“哥哥，为什么金融专业要学‘未来与选择’喵？是生涯规划课吗?”

当看到书上的“futures and options”时，我忍俊不禁，实在不行了，便抵住桌面，防止自己掉下去。

“这是‘期货与期权’呀，这么奇怪的误解，还是头一次听到呢。”

“哥哥太讨厌了，居然嘲笑人家！小心人家找米尔嘉大人告状!”

这一下弄得我有些哭笑不得。

“好啦好啦，不逗你了。不过这倒是提醒我了，尤里以后想做什么呢?”

“嗯……虽然很喜欢数学，但是数学真的好难喵！那就只能学数学的相关专业了，计算机？金融？还是好难选喵!”

“这么说起来的话，‘数学的无关专业’应该比‘数学的相关专业’更难挑选吧。尤里可不能因为数学难就逃避它啊。”

“哥哥真是的!”

泰朵拉和理纱她们又怎么样？泰朵拉的成绩一直不错，现在数学也越来越好了，不断减小的，也只有离梦想的距离了。至于理纱，双仓博士应该能为她提供很好的资源，她自己也很认真，应该也是不成问题的。

米尔嘉是神，常人是无法理解神明的；我只是个喜欢数学的普通人，必然要直面这千变万化、光怪陆离的世界。

我能感受到米尔嘉的决心，但是，真的能做到一辈子吗？

⊙ ⊙ ⊙

“我跟村木老师提过了，*Eulerians* 会发展新成员！”泰朵拉还是像往常一样热情洋溢。

“新一期的初稿写好了，尝试了新的排版工具 Liii STEM。这个工具比较好用，更容易教会新成员。”

“我也写了一篇文章，题目是欧拉对统计学的奠基性贡献。”米尔嘉将手稿递给理纱。

“差一点 *Eulerians* 就没有欧拉了喵。”

“欧拉对统计学的贡献，我想想”，我脑中闪回若干数学公式，“像 Gamma 和 Beta 函数这样的？”

“不止这些，欧拉对现代统计学所需的必需数学工具做了大量的工作，比如他处理天文数据的方法，已经有了最小二乘法的雏形。”

“说起来……米尔嘉学姐是不是马上要回去了？”泰朵拉略有伤感。

“嗯，那边还有很多工作。现在主要是对各种方向做通识性的了解，也包括应用数学，特别是机器学习这一块。当然，我的想法还是继续做纯数学，但通识涉猎也是极为重要的。”

“那个模型最后怎么样了？”我问。

“后面理纱又做了一些优化，然后我给老板汇报了相应的结果，现在便利店的经营状况显著改善了。”泰朵拉又流露出一丝喜悦。

“p 值小于 0.05，显著改善。”理纱少有的幽默令大家会心一笑。

“问个问题，”米尔嘉看向我，“如果把 $\mathcal{N}(\mu, \sigma^2)$ 中的参数 μ 或者 σ^2 看作随机变量并讨论其分布，会发生什么？”

“把固定的参数看作随机变量吗？有点意思，好像贝叶斯估计里面会用到。”

“这个问题挺有意思的，我刚好最近了解了一些贝叶斯学派的观点，可以给大家讲讲。”

终于可以休息一下了，我心想。

“贝叶斯？人家只知道贝叶斯公式喵。米尔嘉大人说的贝叶斯学派，一定是很厉害的东西吧！”

米尔嘉笑着摸了摸尤里的脑袋。

“不管怎样，大家以后要一……一起讨论数学啊。”

我想到了那天的“一辈子”，却不知怎的说不出口。

6.2 频率学派与贝叶斯学派

首先我们从频率学派出发。频率学派将概率视为一个客观量，用于描述频率稳定后的值。我们熟悉的大数定律描述的就是频率的稳定性。

贝叶斯学派正好相反，他们将概率视为一个主观信念，并且能够随着观测到的样本进行修正。其核心正是尤里提到的贝叶斯公式。

$$P(A|B) = \frac{P(A)P(B|A)}{P(B)}$$

这个公式看起来平平无奇，因为只需要代入条件概率的定义就可以轻松得到这个等式。但是，其中蕴含了重要的思想。我们关于事件 A 存在先验知识，在这里体现为先验概率 $P(A)$。而当我们得到观测 B 的时候，我们会修正对事件 A 的概率估计为 $P(A|B)$，这就是后验概率。这里的 $P(B|A)$ 好像就是在先验的条件下观测的合理程度，我们把它称为似然概率。

“明白了喵，先验概率经过观测的修正就得到后验概率了，所以我们可以利用数据对概率不断修正，从而得到更准确的概率。”

贝叶斯学派不仅认为概率能被修正，他们还认为参数估计中的参数也能够通过观测样本不断修正。换言之，他们认为参数本身也是随机变量。我们假设总体服从参数为 θ 的某种分布，并且我们得到了一组样本 X。代入贝叶斯公式，可以得到：

$$P(\theta|X) = \frac{P(\theta)P(X|\theta)}{P(X)}$$

“米尔嘉学姐，我有些不明白，这里的 $P(\theta)$ 是表示关于参数 θ 的某一个事件的概率吗？它好像并没有说这个事件是什么。”

这里的 P 不完全代表事件，它代表的实际上是一个分布。比如 $P(\theta|X)$ 是在给定观测 X 的情况下参数 θ 的后验分布。为了避免混淆，有时我们也使用概率密度函数 $f(\cdot)$ 或者 $p(\cdot)$ 来代替上面的 $P(\cdot)$。

问题 6.2.1

对物体的真实质量 μ（单位：克）进行估计，已知测量仪器的误差服从正态分布，且方差 $\sigma^2 = 1$（即测量值 $X \sim \mathcal{N}(\mu, 1)$）。现在进行一次测量，得到 $X = 10$。采用先验 $\mu \sim \mathcal{N}(\mu_0, \tau_0^2)$，其中 $\mu_0 = 10, \tau_0^2 = 4$，求 μ 的后验分布。

我们可以先写出贝叶斯公式。

$$p(\mu|X) = \frac{p(\mu)p(X|\mu)}{p(X)}$$

其中的先验分布 $p(\mu) = \frac{1}{\sqrt{2\pi}\tau_0} \exp(-\frac{(\mu-\mu_0)^2}{2\tau_0^2})$ 是我们熟悉的正态分布，似然函数 $P(X|\mu) = \frac{1}{\sqrt{2\pi}\sigma} \exp(-\frac{(X-\mu)^2}{2\sigma^2})$ 也很好求得。贝叶斯估计的难点就在于用积分计算 $p(X)$。

$$p(X) = \int_{\mu \in \mathbb{R}} p(X|\mu)p(\mu)d\mu$$

根据微积分，我们可以算得 $p(X)$。

$$\begin{aligned} p(X) &= \int_{\mu \in \mathbb{R}} \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(X-\mu)^2}{2\sigma^2}\right) \cdot \frac{1}{\sqrt{2\pi}\tau_0} \exp\left(-\frac{(\mu-\mu_0)^2}{2\tau_0^2}\right) d\mu \\ &= \frac{\exp(-\frac{(X-\mu_0)^2}{2(\sigma_0^2+\tau_0^2)})}{\sqrt{2\pi}\sigma\tau_0\sqrt{\frac{1}{\sigma^2}+\frac{1}{\tau_0^2}}} \end{aligned}$$

我们略去代入后复杂的代数变形，最终会得到 μ 的后验分布也是一个正态分布：

解答 6.2.1

$$p(\mu|X) \sim \mathcal{N}(\mu_1, \sigma_1^2)$$

其中，$\mu_1 = \frac{\frac{\mu_0}{\tau_0^2} + \frac{X}{\sigma^2}}{\frac{1}{\tau_0^2} + \frac{1}{\sigma^2}} = 10$，$\sigma_1^2 = \frac{1}{\frac{1}{\tau_0^2} + \frac{1}{\sigma^2}} = 0.8$。

虽然后验均值没有变化，但是后验方差从 4 降低到了 0.8，表明我们对 μ 的不确定度降低了。

贝叶斯估计的好处就是我们可以在小样本的情况下利用先验知识提升估计的准确度，这一思想在机器学习中体现为贝叶斯网络。

还记得区间估计吗？我们对 95% 置信区间的解释是“针对不同组样本用同样的方式构造出的所有区间中，有 95% 的区间会覆盖真实值”，这就是把真实值看作是一个固定不变的值的频率学派。在贝叶斯学派中，由于参数被看作随机变量，我们终于可以说“参数有 95% 的可能性落在区间中”，只不过此时我们将这个区间称为可信区间。

$$P(\theta \in CI|X) = 0.95$$

需要注意的是，不同的先验方法会导致不同的可信区间。此外，可信区间是基于观测数据的，而频率学派的置信区间是在所有可能数据上平均的。

⊙　⊙　⊙

“原来参数也能看作随机变量喵。那在贝叶斯学派之前，参数只

能是固定值，这是说数学的定义也会变化吗?”

“数学一直在变。”米尔嘉说，“而且几乎每一次数学的变化，都伴随了我们看待世界的方式的变化。因此，数学往往走在其他科学的前面，比如黎曼几何就远远走在了广义相对论的前面。”

“这个我好像在库恩的书上看到过，”泰朵拉想到了些什么，“范式转换。数学的变化应该就是范式转换的先导。”

“《科学革命的结构》，我在图书馆里读过”理纱开口，“对参数的认知从客观存在变成主观信念，是新旧范式之间存在不可通约性的例子。”

“范式，就是 paradigm 吗？这样说起来，这种范式转换的例子还不少。像从传统统计到机器学习，应该也算是一个重要的范式转换吧?”泰朵拉说。

“纯数学会走在范式转换——科学革命之前，而应用数学则在科学革命的剧变过程中，提供更直接的武器。”我补充道。

“纯数学和应用数学真是一对苦命鸳鸯喵。”

“库恩……科学革命……范式……这书听起来有点意思，我也去找来看看。”

这场关于贝叶斯学派的讨论，最终以大家的沉思收尾。

6.3 深度学习与人工智能

科学革命……范式转换……回到家后，我还在思考刚才讨论的问题。

这场讨论已经有些超出数学的范畴，指向某些更宏大的命题。

《科学革命的结构》……不像是理纱会去读的书。不过，里面所

讲的内容倒是和我们的讨论非常相关。

“哥哥，什么叫‘现如今人工智能的主流范式是数据驱动’喵?”尤里找到了一本介绍人工智能的书。

“原来是对人工智能感兴趣啊。数据驱动，就是用大量数据来训练模型，然后让模型帮助我们解决问题。”

“用数据来训练模型……就是理纱做的那部分吧。这个模型最终帮助我们解决了便利店的客流量预测问题，所以这就是人工智能?这本书里面还讲到了神经网络和深度学习之类的，但是都是矩阵和微积分，完全看不懂喵。”

“这个……人工智能确实就是让机器拥有像人类一样进行各种决策任务的能力。之前我们是不是用了包括线性回归在内的很多机器学习算法？深度学习只不过是利用多层神经网络进行机器学习的算法罢了。”

“神经网络，就是像我们脑子里的神经通路一样的东西喵?”

“没错，发明它的时候就是类比人脑的神经元来命名的。但是实际上它只是一个非常复杂的，用很多线性变换和非线性激活函数做成的一个复合函数罢了。它比我们之前的线性模型或者树模型要复杂得多。人们发现用这种复杂的函数来做机器学习的效果很好，于是就给这种东西起了个时髦的名字，也就是‘深度学习’。”

“一个复杂的复合函数?那训练它一定要很多很多数据吧……原来如此！这就是‘数据驱动’喵。像之前便利店的数据样本还不够多，所以不能用深度学习，对不对?”

“没错。第一是数据量小，第二是函数太复杂容易解释不清，所以我们最终采用的是传统机器学习的方法。由于深度学习太过特殊，所以人工智能学术界说‘机器学习’的时候，往往指的是‘传统机

器学习’。理纱好像在学这方面的东西，你可以问问她。”

⊙ ⊙ ⊙

“程序把输入图像自动变成高维向量，然后经过若干卷积层和池化层，最终经过一个全连接层，利用 Softmax 得到图像为每一种类别的概率。”理纱像机关枪一样讲完了程序的运行过程。

“什么卷积池化，完全听不懂喵！不过直接把图像变成的高维向量扔进一堆东西里面，就是我们不用再像之前一样，手动提取各种特征了喵？直接让程序自己看就行了。”

理纱停了下来，眼里充满了惊叹。

“程序会自己读图，通过隐藏层运算自己给出分类结果，中间不需要人为对图像进行特征提取，这就是深度学习的端到端特点。你已经理解了重点，接下来只要学好数学就可以了。”

“原来中间还是数学喵——”

随后，理纱又展示了更多的深度学习程序。

“这个是预测蛋白质结构的，这个是在给定段落之后不断续写的，这个是在照片里面找出指定物体的……”

“深度学习好厉害喵！”

“可惜它不是万能的，还有很多事做不到，也还有很多机制没有搞清楚。”理纱说，“不过短短十几年就创造了新的主流范式，确实体现了其价值。”

⊙ ⊙ ⊙

这应该是米尔嘉回去前，大家的最后一次见面。为了显得轻松，地点选在了熟悉的“豆子”咖啡馆。

“现在人工智能里最流行的概念是大模型。”泰朵拉率先发言，“Scaling Law，也就是缩放定律，提出当我们让模型变得更加复杂，让数

据更多，模型就会表现得更好。而大模型，就是将模型复杂度和数据量做到极致后，得到的具有强大能力的深度学习模型。”

“这样的‘好日子’能持续多久，是个大问题。”理纱说。

“大模型用到的数学工具同样不新鲜。注意力机制和 Transformer 架构仍然利用的是线性代数和微积分，用以计算概率分布。换言之，其底层原理仍是基于统计的深度学习。”米尔嘉说，“数学原理本身不复杂，但算力的进步推动了模型的大规模预训练和工业化部署。通过预训练得到的通用模型，稍加微调就可以应用于各种专业任务上。”

“复杂复合函数不好解释，这是个问题。”尤里托着脑袋思考，“比如金融里面，涉及到风险决策的部分，深度学习解释不清的话，没人敢承担这个责任。特别是像期货与期权这样复杂的金融工具——我才不会再把它们当成‘未来与选择’呢！”想到了那天的事，尤里瞪了我一眼。

“让计算机像人类一样自主进行决策绝非易事。我们先前训练的模型只有非常简单的几个特征，而现实世界的大量特征非常难以处理。”理纱边说边在笔记本上写着，“从基于知识表示和推理的符号主义范式，到以机器学习和深度学习的数据驱动范式，再到以大规模预训练模型为代表的范式，人工智能的发展比其他学科快得多。但是，距离实现通用人工智能还非常漫长，未来很可能还需要新的范式。”理纱边说边画了个大大的问号。

“纯数学的范式变化不会这样快，这未必不是件好事。”米尔嘉推了推眼镜，“不过数学家倒是也开始用大模型来辅助证明了。为了提高证明的可靠性，他们将大模型与符号主义的 Lean 语言进行结合，利用形式化推理方法验证大模型结果的正确性。不过也有些不

负责任的人会直接将大模型的结果投到 arXiv 上。”

“这种做法确实很误导人。成为一个负责任的 AI 使用者是我们这个时代的必修课。”我又有了一些想法，“刚刚理纱提到了通用人工智能，我也觉得现有的黑箱式模型没有办法真正让 AI 充分对自己的决策负责。比如大模型的幻觉现象，到现在也没有完全解决，尽管有很多初步的方法。”

“看来还是要可解释才行喵。”

这样的讨论进行了好一阵子，直到咖啡馆快关门了，大家才意识到时间已经过去很久了。

夕阳下，泰朵拉率先做起斐波那契手势，随后大家响应，标志这次讨论的结束。

“Should auld acquaintance be forgot, and never brought to mind ...”我听见了泰朵拉低声的歌唱。

……

“We’ll take a cup of kindness yet, for auld lang syne.”[①] 大家也不自觉地和着歌声唱了起来。

真的要说再见了吗？

高考的日子越来越近，泰朵拉即将面临人生的重要时刻，尤里和理纱也将踏上新学期的旅途。

米尔嘉……

“一辈子……”

这份决心，我记住了。

[①]苏格兰民歌 *Auld Lang Syne*，曲名中文常译作《友谊地久天长》。

6.4　向夜晚奔去

沈むように溶けてゆくように——

二人だけの空が広がる夜に——[①]

这样的日子果然还是要结束啊，我一边听歌一边想。夜渐渐深了，这首歌显得格外应景。

在通常的意象上，夜晚可以是短暂的黑暗，第二天的白昼终将到来。但在这首歌里，情况却截然相反。

频率学派的瓦解，深度学习的兴起，这一切都是确定性消失的实证，我们终将陷入一场永不破晓的夜中。

幸运的是，我不必向歌的主人公一样，在塔纳托斯的诱惑下走向自我毁灭[②]。我得以同志同道合的朋友们一起，持有数学与逻辑的武器，在那永不破晓的黑夜中开辟一条光明的道路。

又是半年的长别。下一次的重逢，也能像这次一样，在永不破晓的夜中带来短暂的明亮吗？

⊙　⊙　⊙

米尔嘉走的那天，她们都有课。

电车在轨道上飞驰，景物不断出现在眼前，我竟有些分不清这是真是幻。

“关于可解释性的问题，现在可解释 AI 已经发展成一套较为丰富的理论，或许是破解你说的‘永夜’的出路。话说你是怎么想到这样的比喻的？这有些不太像你。”

[①] YOASOBI《夜に駆ける》

[②] 星野舞夜《タナトスの誘惑》

“这也是我突然想到的，毕竟有些时候，事物的诞生需要的是灵感。”

“不错，灵感确实很重要。数学家丘成桐就以诗经的‘比兴’手法作譬喻，从而说明想象和灵感在创造数学概念中的重要性。”

“说到这个，我想到一首诗里面的一组‘不可能事件’，不过不是诗经，是中国汉代的乐府诗”。

“哦，这里面还有概率论?”米尔嘉来了兴趣。

“‘山无陵，江水为竭，冬雷震震，夏雨雪，天地合’，这听着就不可能吧。”

“原来是这个。”米尔嘉忍俊不禁，脸颊微微泛红，“这是表示决心的句子吧？那我们约定，一起讨论数学直到这一组事件发生，如何?”

“那当然，某人曾说要‘一辈子’一起讨论数学的。”

“一言为定。”

轻松的玩笑难免离别的不舍，随着列车到站，我们沉默着前往机场。

“保重，记得照顾好她们。”这是米尔嘉走之前的最后一句话。

等到我离开机场的时候，已经是深夜了，电车上的人比来时更少。

但我已不再害怕了。

⊙ ⊙ ⊙

“*Eulerians* 大获成功！真希望米尔嘉学姐也能看到。”泰朵拉拿着几本样刊走了进来。

“电子版已经发给她了。那个新软件挺好用的，给 *Eulerians* 的排版帮了大忙。”理纱露出了为数不多的笑容。

是日，晴空万里，大家的脸上满是喜悦。

“大家对我们的便利店实际案例非常感兴趣，很多人甚至在复现和改进我们的模型了。米尔嘉学姐的文章也受到了关注，村木老师的好多新卡片都是从里面来的。还有尤里写的简易量化金融模型，也非常有吸引力。”

“这次绝对没有把‘期货与期权’搞错喵。”

“期货与期权很神奇，但是未来与选择同样重要。让我们为了各自的理想，努力奋斗吧！”

“哥哥怎么又在嘲笑我喵！”

尾声

“老师，我们已经得出结论了，误差独立同分布服从正态分布的情况下最大似然估计和最小二乘法等价！”

少女爽朗的声音又一次出现在了午间的办公室。

“那个深度学习模型效果一直不太好，容易过拟合，换成传统机器学习之后好多了。我们把这些工作都写到新一期的社刊里面了，现在有很多同学意向加入呢！”

“看来有的时候还是传统方法效果更好啊。当年我也跟她们一起做了一个机器学习模型，想想真是怀念啊。”

“老师，这次的新卡片好了吗？”

“已经好了。这次的卡片都是和贝叶斯学派相关的，有点挑战性。”

“没关系！数学总是要挑战才有乐趣嘛。虽然现在大模型能解决各种问题，但自己动手发现的体验是无可替代的。”

少女迈着轻松的步子离开了办公室。

“这就是青春啊……”

正当我遐想时，一个熟悉的账号发来消息。

“我今天有个报告，在西湖大学，欢迎直播观看。”

是米尔嘉，报告的主题是形式语言与可解释 AI。但是西湖大学，倒是没有听说过。

“西湖大学，是中国的大学吗？”我试探地提问。

“是中国杭州的大学。那里的交叉学科氛围很浓厚，非常欢迎我的报告题目。”

“杭州，就是马可波罗笔下的‘天城’吗？真希望能亲眼去看看。”

“杭州也是人工智能和科技创新的高地，对我来说也是一次深入了解数学实际应用的机会。”

这种讨论似乎把相去甚远的我们又紧密连结在一起。

“答应我，如果有机会，一定要来这里看看，好吗？”

“一言为定。”

西湖大学，想必一定离美丽的西湖很近吧。在这样的环境里面做研究，又是怎样的一种体验呢？我又陷入了新一轮的遐想之中。

【《数学女孩》同人：统计推断篇（完）】

后记

感谢你读到这里！

本文是结城浩《数学女孩》系列的同人作品，其质量显然无法与结城浩先生本人相比。本人水平有限，出现疏漏和不合理之处在所难免，请见谅。

写作本同人作品的契机是 2025 秋学期在西湖大学上过的由佘轶原老师主讲的课程“概率论与数理统计 A”，从中感受到了统计学的魅力以及佘老师对本科生教学的不遗余力。可惜这样一门课程因为教学事务部的安排以后将不再开设，且佘老师也将更多承担研究生的教学任务。我出于对这门课程的喜爱，以及对《数学女孩》这样一部从初中陪伴到我现在的优秀作品的眷恋，写下这篇同人作品。虽然写得不是很好，但这确实是我凭借自身对原作的理解而一字一句敲下的。当然，在情节构思、数学知识推导上面，我获取了 DeepSeek、豆包等大模型的一定帮助[①]。

这并不是一本计划要公开发表到什么地方去的作品，所以整部作品，包括这段后记，也许只是自娱自乐吧。如果这部作品有幸被他人阅读，我将不胜感激。

最后，再次将结城浩的《数学女孩》系列推荐给大家。该系列

[①]具体而言，包括第 5 章数据科学项目的问题提出、数据集生成和文中的部分代码撰写，以及相关统计分布推导的校验。

的前 6 册国内目前已经由人民邮电出版社引进出版，相信《数学女孩 7：黎曼猜想》最终也能成功引进出版。原作写得比我好得多，所以如果我写得非常离谱，纯属我比较唐，绝对不是原作的问题。

Monikalover

2026 年 3 月于西湖大学云谷校区

$$\lim_{n\to\infty} P(Z_n \leqslant \heartsuit) = \int_{-\infty}^{\heartsuit} \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right) dx = \Phi(\heartsuit)$$